

POLITECHNIKA WROCŁAWSKA
WYDZIAŁ ELEKTRONIKI

KIERUNEK: Informatyka (INF)
SPECJALNOŚĆ: Systemy informatyki w medycynie (IMT)

**PRACA DYPLOMOWA
MAGISTERSKA**

Analiza jakości wybranych metod nadzorowanego
uczenia sztucznych sieci neuronowych

Qualitative analysis of selected methods of
supervised learning of artificial neural networks

AUTOR:
Sławomir Żaba

PROWADZĄCY PRACĘ:
dr inż. Edward Puchała

OCENA PRACY:

Spis treści

1	Wstęp	3
1.1	Cel i zakres pracy	4
2	Opis problemu	5
2.1	Rak piersi, jako badany przypadek medyczny	5
2.2	Opis wykorzystanego zbioru danych	6
2.3	Przygotowanie zbioru danych	7
2.3.1	Kodowanie z gorącą jedyneką	7
3	Sztuczne sieci neuronowe	9
3.1	Historia	9
3.2	Budowa biologiczna	10
3.3	Model sztucznego neuronu	11
3.4	Podział sieci neuronowych	11
3.4.1	Sieci jednokierunkowe	12
3.4.2	Sieci rekurencyjne	12
3.4.3	Sieci komórkowe	13
3.5	Uczenie sieci neuronowych	13
3.5.1	Proces uczenia sieci neuronowych	14
3.5.2	Uczenie nadzorowane	14
3.5.3	Uczenie nienadzorowane	15
3.6	Wybrane algorytmy uczenia nadzorowanego	15
3.6.1	Algorytm wstecznej propagacji błędów	16
3.6.2	Algorytm zmiennej metryki	19
3.6.3	Algorytm gradientów sprzężonych	20
4	Implementacja aplikacji komputerowej	21
4.1	Opis wykorzystanych narzędzi	21
4.1.1	Język Python	21
4.1.2	Biblioteki zewnętrzne	22
4.1.3	Wirtualne środowisko	25
4.1.4	System kontroli wersji GIT	25
4.2	Opis działania programu	26
5	Wyniki eksperymentów	29
5.1	Algorytm wstecznej propagacji błędów	29
5.2	Algorytm zmiennej metryki	51
5.3	Algorytm gradientów sprzężonych	56
5.4	Porównanie wyników	77

6 Podsumowanie	79
Bibliografia	79
Spis rysunków	82
Spis tabel	83

Rozdział 1

Wstęp

W ostatnich latach dynamicznie wzrasta zainteresowanie sztucznymi sieciami neuronowymi. Dzieje się tak, ponieważ mózg ludzki uznawany jest za wzór w problemach przetwarzania informacji i szukania w nich zależności. Próbując odtwarzać zasady jego działania powstawały i wciąż powstają grupy algorytmów, które w ogólnym pojęciu noszą nazwę sztucznych sieci neuronowych. Na dzień dzisiejszy algorytmy te znajdują zastosowanie niemalże w każdej dziedzinie życia człowieka. Mogą one służyć do rozwiązywania bardzo wielu różnych typów zadań. Swoje zastosowanie znajdują wszędzie tam, gdzie występują problemy związane z predykcją, czy też klasyfikacją. Jak nietrudno spostrzec z tego typu problemami mamy do czynienia także w medycynie, gdzie przy wykorzystaniu sztucznych sieci neuronowych na podstawie kluczowych cech i atrybutów można diagnozować choroby. Niniejsza praca i badania w niej zawarte dotyczą właśnie tej dziedziny życia. Aplikacja komputerowa stworzona dla celów pracy ma służyć do diagnostyki raka piersi, a klasyfikatorem użytym do podejmowania decyzji ma być sieć neuronowa. Głównym zadaniem jest analiza wybranych algorytmów uczenia nadzorowanego i rozstrzygnięcie, który z nich daje najlepsze rezultaty, w jakich warunkach. Sam przypadek medyczny ma drugorzędne znaczenie, bo jak już wcześniej wspomniano zarówno sieci neuronowe, jak i wykorzystane algorytmy uczenia można wykorzystać do każdego innego problemu.

Struktura pracy przedstawia się następująco. W niniejszym rozdziale zostanie jeszcze opisany cel oraz zakres pracy. W rozdziale drugim zostanie lepiej przybliżony główny problem oraz opisane zostaną podstawowe pojęcia związane z jego tematyką. W rozdziale trzecim szczegółowo zostaną omówione sieci neuronowe, ich sposób działania, algorytmy uczenia nadzorowanego oraz podstawowe pojęcia związane z tą tematyką. Rozdział czwarty poświęcony został opisaniu zaimplementowanej aplikacji. Znajdą się w nim informacje na temat sposobu działania aplikacji, narzędzi z jakich skorzystano w trakcie jej tworzenia oraz opisane zostaną czynności związane z przygotowaniem danych, jakie aplikacja musi wykonać przed rozpoczęciem działania algorytmów uczenia. Rozdział piąty przedstawia wyniki oraz analizy badań przeprowadzonych na działającej aplikacji. Rozdział szósty jest podsumowaniem całej pracy.

1.1 Cel i zakres pracy

Celem pracy jest stworzenie aplikacji komputerowej służącej do diagnostyki raka piersi u kobiet. Aplikacja ta musi być sparametryzowana i za pomocą argumentów można między innymi zmienić:

- algorytm uczenia nadzorowanego (do wyboru jeden z trzech algorytmów);
- liczbę epok;
- współczynnik uczenia;
- procentowy rozmiar zbioru testującego.

Stworzenie takiej aplikacji pozwoliło na przeprowadzenie badań i eksperymentów, dzięki którym można było porównać wybrane algorytmy uczenia nadzorowanego pod różnymi kątami. Na ich podstawie będzie można stwierdzić między innymi, czy wybór algorytmu ma wpływ na wyniki otrzymywane z sieci neuronowej, jakie są optymalne parametry sieci dla różnych metod uczenia oraz czy wybór metody ma wpływ na długość procesu uczenia.

Aby zrealizować opisany powyżej cel pracy należało wykonać wiele zadań, w skład których wchodziło:

- zapoznanie się z teorią uczenia sztucznych sieci neuronowych;
- wybranie algorytmów nadzorowanego uczenia sieci neuronowej i ich implementacja;
- zaprojektowanie eksperymentów badawczych;
- przeprowadzenie testów przy uwzględnieniu kryteriów analizy porównawczej;
- opracowanie wyników analizy i wyciągnięcie wniosków.


Rozdział 2

Opis problemu

Niniejszy rozdział opisuje pokrótce problem medyczny, z jakim się zmierzono w ramach pracy dyplomowej, czyli nowotwór piersi. Zostanie w nim przedstawiona krótka charakterystyka tej choroby oraz zbiór danych jaki wykorzystano w zaimplementowanej aplikacji, tzn. zostaną scharakteryzowane wszystkie atrybuty oraz klasy, jakie zostały udostępnione. Ponadto w rozdziale został opisany proces, w jaki przygotowano dane znajdujące się w zbiorze, aby były odpowiednie do wykorzystania w algorytmach uczeniach nadzorowanego sieci neuronowych.

2.1 Rak piersi, jako badany przypadek medyczny

Rak piersi to nowotwór złośliwy wywodzący się z nabłonka gruczołu sutkowego i jest to to najczęściej występujących nowotworów wśród kobiet w Polsce i jeden z najczęściej występujących na świecie. W samym 2015 r. zmarło z tego powodu 561 tysięcy kobiet. Najczęściej rozwija się u kobiet między pięćdziesiątym a siedemdziesiątym rokiem życia i to one są w grupie największego ryzyka zachorowania. Co ciekawe, nie tylko kobiety narażone są na wystąpienie tego rodzaju nowotworu. W gronie osób chorych znajdują się także mężczyźni, choć jest ich zdecydowana mniejszość. Poniżej została przedstawiona ilustracja przedstawiająca zdjęcia z mammografu, czyli urządzenia, za pomocą którego można badać piersi. Pierwsze z nich przedstawia zdrową pierś, drugie z kolei przedstawia pierś posiadającą guza.



Rysunek 2.1: Porównanie zdrowej piersi z zainfekowaną przez nowotwór

Źródło: [5]

Nowotwór sam w sobie jest chorobą spowodowaną niekontrolowanym rozrostem komórek pochodzących z danej tkanki lub narządu. Złośliwe komórki raka mogą rosnąć, co prowadzi do pojawienia się guza, który może powodować uciski, a ponadto rozprzestrzeniać się poprzez krew po całym organizmie powodując powstanie tak zwanych przerzutów. Wczesnie wykryty rak piersi daje szansę na całkowite jego wyleczenie, dlatego też ważne jest jego zdiagnozowanie w jak najszybszym czasie. Ryzyko, że rak piersi doprowadzi do śmierci jest niskie, ale pod warunkiem, że guz w momencie wykrycia nie przekracza 0,5 cm średnicy.

2.2 Opis wykorzystanego zbioru danych

Zbiór danych wykorzystany do testowania algorytmów uczenia nadzorowanego został pobrany z repozytorium ICS.UCI i jest on dostępny pod linkiem:

[https://archive.ics.uci.edu/ml/machine-learning-databases/
breast-cancer-wisconsin/breast-cancer-wisconsin.data](https://archive.ics.uci.edu/ml/machine-learning-databases/breast-cancer-wisconsin/breast-cancer-wisconsin.data).

Dane o raku piersi otrzymano z uniwersytetu znajdującego się w stanie Wisconsin od doktora Williama H. Wolberg'a w 1991 roku. Baza ta zawiera 699 instancji, gdzie 16 z nich posiada brakujące wartości, stąd też nie były one brane pod uwagę przy procesie uczenia sieci. Z pozostałych 683 instancji, 239 to nowotwory złośliwe, a pozostałe 444 to nowotwory łagodne. Każda z instancji charakteryzowana jest przez 10 cech, które zostały poniżej opisane:

- Sample code number - oznacza identyfikator pacjenta. Parametr ten nie jest brany pod uwagę przy procesie uczenia sieci;
- Clump Thickness [1-10] - komórki łagodne mają tendencję do grupowania w monowarstwach, podczas gdy komórki rakowe są często grupowane w wielowarstwowe;
- Uniformity of Cell Size / Shape [1-10] - komórki rakowe mają różny rozmiar i kształt. Dlatego te parametry te są cenne przy określaniu, czy komórki są rakowe, czy nie;
- Marginal Adhesion [1-10] - normalne komórki sklejają się ze sobą. Komórki rakowe tracą tę zdolność, co jest oznaką złośliwości nowotworu;
- Single Epithelial Cell Size [1-10] - parametr związany z wyżej wspomnianą jednolitością. Komórki nabłonkowe, które są znacznie powiększone, mogą być komórkami złośliwymi;
- Bare Nuclei [1-10] - termin używany w jądrach komórkowych, które nie są otoczone przez cytoplazmę. Zazwyczaj są one widoczne w łagodnych nowotworach;
- Bland Chromatin [1-10] - parametr opisujący, jak jednolitą strukturę chromatyny w jądrze komórkowym. W komórkach nowotworów złośliwych chromatyna ma skłonność do większej szorstkości;
- Normal Nucleoli [1-10] - parametr mówiący o wielkości jądra w komórce. W normalnych komórkach jądro jest zwykle bardzo małe, czasem w ogóle niewidoczne. W komórkach nowotworowych jądra stają się bardziej widoczne, w pewnych sytuacjach ich liczba może się nawet zwiększać;

- Mitoses [1-10] - częstotliwość procesu podziału pośredniego jądra komórkowego.

Ponadto do każdej z instancji przypisana jest klasa - wartość 2 dla nowotworu łagodnego oraz 4 dla nowotworu złośliwego.

2.3 Przygotowanie zbioru danych

W celu poprawnego działania sieci neuronowej należy poprawnie zdefiniować dane wejściowe. Niezależnie od badanego przypadku powinny one spełniać warunki, takie jak reprezentatywność, pełne oddanie problemu, odpowiednie przeskalowanie i normalizacja. Przeprowadzenie takowych zabiegów jest niezbędne do odpowiedniego działania sieci. Wszystkie z kroków przygotowania danych zostały opisane poniżej. Wykonują się one w stworzonej aplikacji komputerowej przed rozpoczęciem procesu uczenia.

Na samym początku przygotowywania danych usuwane są rekordy zawierające brakujące informacje. Zabieg taki wykonano, aby nie został zaburzony proces uczenia i brakujące wartości nie wpływały na jakość późniejszej klasyfikacji. Ze względu na fakt, że w opisywanym zbiorze znajdowało się ledwie szesnaście takich rekordów, to liczba instancji zmalała do 683.

Kolejnym etapem przygotowania danych było usunięcie pierwszej kolumny zatytułowanej "Sample code number". Czynność ta została wykonana ze względu na fakt, że jest to tylko identyfikator, który nie wnosi żadnych ważnych informacji w kontekście klasyfikacji.

Następną czynnością jaką wykonano była normalizacja danych wejściowych, czyli wszystkich cech opisanych w wcześniejszej części. Dane wyjściowe natomiast zostały zakodowane za pomocą tzw. kodowania z gorącą jedyneką (ang. one hot encoding). Taki sposób kodowania został opisany w dalszej części niniejszego rozdziału.

Ostatnim etapem był losowy podział danych na zbiór trenujący oraz testujący. Krok ten jest po części sparymetryzowany, gdyż użytkownik programu może sam zdecydować, jakiej wielkości może być zbiór testujący.

2.3.1 Kodowanie z gorącą jedyneką

Ze względu na fakt, że w trakcie przygotowania danych użyto kodowania z gorącą jedyneką, to postanowiono wytłumaczyć, czym charakteryzuje się ów rodzaj kodowania. Podstawowym rodzajem kodowania jest kodowanie całkowitego, które polega na tym, że każdej unikalnej wartości kategorii przypisuje się wartość całkowitą. Na przykładzie projektu takie przypisanie wygląda następująco: "benign" - \rightarrow 1, "malignant" - \rightarrow 2. Niestety dla pewnego rodzaju zmiennych kodowanie całkowite nie jest wystarczające. Okazuje się, że użycie tego sposobu kodowania i umożliwienie modelowi przyjęcia naturalnej kolejności między kategoriami spowodowało, że sieć neuronowa dawała słabe rezultaty. Wstępne wyniki sprawiły, że w projekcie zaimplementowano **kodowanie z gorącą jedyneką (ang. one hot encoding)** do reprezentacji całkowitej. Dla celów projektu potrzebne były 2 zmienne binarne i po zakodowaniu rozpatrywanych klas wyglądały one następująco: "benign" - \rightarrow [1, 0], "malignant" - \rightarrow [0, 1].

Rozdział 3

Sztuczne sieci neuronowe

Niniejszy rozdział poświęcony jest całkowicie sieciom neuronowym. Zostanie w nim opisana geneza sieci neuronowych, a także zostaną objaśnione jej własności, modele oraz, co najważniejsze algorytmy uczenia, w tym głównie metody uczenia nadzorowanego ze względu na to, że jest to główna tematyka pracy dyplomowej.

3.1 Historia

Pojęcie sieci neuronowych jest całkiem nowym pojęciem w literaturze. Niech świadczy o tym fakt, że początki tej dziedziny zaistniały dopiero w 1943 roku, kiedy to została wydana praca McCulloch'a i Pitts'a. W pracy tej pierwszy raz został opisany matematyczny model neuronu, a także powiązано go z problemem przetwarzania danych. Praca ta spowodowała, że w późniejszych latach nastąpił ogromny rozwój sieci neuronowych. 1949 rok był kolejnym ważnym wydarzeniem w tej dziedzinie, a mianowicie Donald Hebb, słynny kanadyjski psycholog, odkrył, że informacja może być składowana w połączeniach między komórkami nerwowymi, co doprowadziło do powstania metody uczenia, zwanej regułą Hebba, polegającej na zmianach wag między neuronami.

Wydarzenia opisane powyżej doprowadziły do coraz to większego zainteresowania budowaniem sieci neuronowych. Pierwszym znanym przykładem takowej sieci był Perceptron, który powstał w 1957 roku i był przedstawiony jako układ częściowo elektromechaniczny, częściowo elektroniczny. sieć ta została stworzona do rozpoznawania znaków, jednak po wielu testach okazało się, że miała ona problemy w przypadku różnej skali obiektów, a ponadto nie rozpoznawała złożonych znaków. Na podstawie tego modelu została stworzona w 1960 roku sieć elektrochemicznych uczących się segmentów. Składała się z powielonych i połączonych elementów Adaline (ang. Adaptive linear element), które łącznie dawały układ Madaline (ang. Many Adaline). Tak skonstruowana sieć wykorzystywana jest obecnie między innymi w radarach, modemach i liniach telefonicznych.

W latach 70-tych książka autorstwa Minsky'iego i Paperta spowodowała znaczne zahamowanie rozwoju badań nad sztucznymi sieciami neuronowymi. Opisany był w niej dowód na to, że sieci jednowarstwowe mają ograniczone zastosowania. Dopiero 15 lat później ukazało się wiele publikacji, które pokazywały, że ograniczenia ukazane w książce Minsky'iego i Paperta nie mają swojego odbicia w sieciach nieliniowych. Prace te pozwoliły wskazać nowy kierunek rozwoju nad sieciami neuronowymi.

Kolejne lata to wciąż ogromny rozwój tej dziedziny. W 1982 roku została opracowana przez Kohonena sieć do wydobywania cech, która uczyła się bez nadzorca (tzw. sieć samoucząca). Ponadto w latach 80-tych pojawiały się kolejne rozwiązania, takie jak sieci


ze sprzężeniem zwrotnym. Na wzrost zainteresowania tą dziedziną miała wpływ książka Andersona, w której wykazał ogromny postęp technologiczny układów potrafiących modelować sztuczne sieci neuronowe. Ukazał również dużą liczbę zagadnień i problemów, które można rozwiązać przy użyciu sieci neuronowych.

Na dobrą sprawę temat sztucznych sieci neuronowych wciąż nie został wyczerpany. Wciąż trwają prace i badania nad poszerzeniem ich możliwości oraz zastosowań. Ze względu na innowacyjność tej dziedziny ludzie wierzą, że wciąż nie zostało odkryte jeszcze wiele mechanizmów i algorytmów, które w znaczny sposób ułatwiłyby rozstrzygnięcie problemów i zagadnień, a które do tej pory nie zostały rozwiązane.

3.2 Budowa biologiczna

W celu lepszego zrozumienia zasad, jakimi należy posługiwać się przy modelowaniu sztucznej sieci neuronowej, trzeba zaznajomić się z budową biologicznych sieci neuronowych. Głównym wzorcem sieci neuronowych, jak nietrudno się spostrzec, jest mózg człowieka. Szacuje się, że średnio ma on objętość na poziomie około 1400 cm^3 i powierzchnię równą około 2000 cm^2 . Jedną z najistotniejszych rzeczy w przypadku rozpatrywania intelektualnych zdolności jest kora mózgowa, która ma średnio 3 mm grubości, zawiera około 1010 neuronów i 1012 komórek glejowych. Przeciętnie liczba połączeń między komórkami to 1015. Rolą komórek nerwowych jest wysyłanie i przyjmowanie impulsów o częstotliwości od jednego do stu Hz, napięciu równym 100 mV i czasie trwania od jednej do dwóch ms. Szacuje się, że mózg ludzki jest w stanie wykonać około 1018 operacji na sekundę.

Neuron znajdujący się na poniższej ilustracji stanowi główny element sieci neuronowej. Taka komórka nerwowa składa się między innymi z somy, wewnątrz której jest jądro. Z każdej somy wychodzą wypustki, które mają duże znaczenie w połączeniu z innymi neuronami. Dzielą się one na dwa rodzaje: cienkie dendryty i grubszy rozwidlający się akson.



Rysunek 3.1: Biologiczny model neuronu


Źródło: [10]

Sygnały wejściowe są doprowadzane do neuronu za pomocą synaps, z kolei sygnał wyjściowy odprowadzany jest przez akson i jego odgałęzienia, które docierają do somy

i dendrytów innych komórek nerwowych. W ten sposób tworzone są synapsy, które dołączają wyjścia innych neuronów do danej komórki. Przekazywanie impulsu nerwowego opiera się na powstawaniu substancji chemicznych zwanych neuromediatorami pod wpływem bodźców pochodzących od synaps. Neuromediatorzy wpływają na błonę komórki, co powoduje zmianę jej potencjału elektrycznego. Ze względu na to, że synapsy różnią się możliwością gromadzenia neuromediatora, impuls na wejściu neuronu może powodować silniejsze lub słabsze jej pobudzenie. Wejściom komórki przypisuje się wagi będące współczynnikami liczbowymi, gdzie każda waga odpowiada ilości neuromediatora wydzielonego na konkretnych synapsach. Po otrzymaniu impulsów i uwolnieniu odpowiedniej ilości neuromediatora następuje pobudzenie neuronu. Komórka nerwowa reaguje na impulsy, jeżeli potencjał jego błony komórkowej osiąga wskazany poziom. Następnie cała substancja jest usuwana.

3.3 Model sztucznego neuronu

Znając właściwości biologiczne i budowę komórki nerwowej, można przedstawić schemat działania sztucznego neuronu. Jak widać na poniższej ilustracji składa się on z wielu wejść, do których doprowadzane są sygnały z warstwy poprzedniej neuronów. Każdy z tych impulsów przemnażany jest przez odpowiadającą mu wagę. Następnie zsumowane iloczyny sygnałów i wag stanowią argument dla funkcji aktywacji, która w zależności od potrzeb, może przyjmować różne postacie.



Rysunek 3.2: Sztuczny model neuronu

Źródło: [10]


Jak widać na zamieszczonej ilustracji, wartość wyliczona przez funkcję aktywacji jest wartością wyjścia neuronu sztucznej sieci neuronowej.

3.4 Podział sieci neuronowych

Podstawowy podział sieci neuronowych bazuje na kierunku przepływu sygnałów w tej sieci oraz na sposobie połączeń neuronów. Każdy z typów opisany w niniejszym podrozdziale ma własne metody uczenia i nie ma możliwości, żeby jakikolwiek algorytm mógł być wykorzystany w dwóch różnych typach sieci. Warto zwrócić uwagę, że w pracy przeprowadzono badania jedynie nad algorytmami uczenia znajdującymi zastosowanie w sieciach jednokierunkowych. Pozostałe typy sieci oraz ich właściwości zostały opisane w niniejszym podrozdziale w celach informacyjnych.

3.4.1 Sieci jednokierunkowe

Jest to typ sieci, który obecnie posiada największe zainteresowanie spośród wszystkich architektur. Dzieje się tak ze względu na ich prostą budowę oraz stosunkowo łatwym do implementacji metodami uczenia. Sieci jednokierunkowe skonstruowane są z warstw z neuronami, gdzie występuje tylko jeden kierunek przepływu impulsów. Ten typ sieci charakteryzuje się posiadaniem warstwy wejściowej, jednej lub wielu warstw ukrytych i warstwy wyjściowej. W każdej z warstw liczba neuronów jest dowolna, aczkolwiek funkcja aktywacji musi być dla każdego neuronu w tej warstwie dokładnie taka sama. Neurony z warstwy wejściowej mają za zadanie wykonać wstępną obróbkę sygnału. Za przetwarzanie decyzyjne odpowiadają z kolei neurony warstw ukrytych oraz warstwy wyjściowej. Ostateczna odpowiedź udzielana jest przez neurony znajdujące się w warstwie wyjściowej. Typowym przykładem tego typu sieci jest perceptron. Poniższa ilustracja przedstawia przykładową strukturę sieci jednokierunkowej.

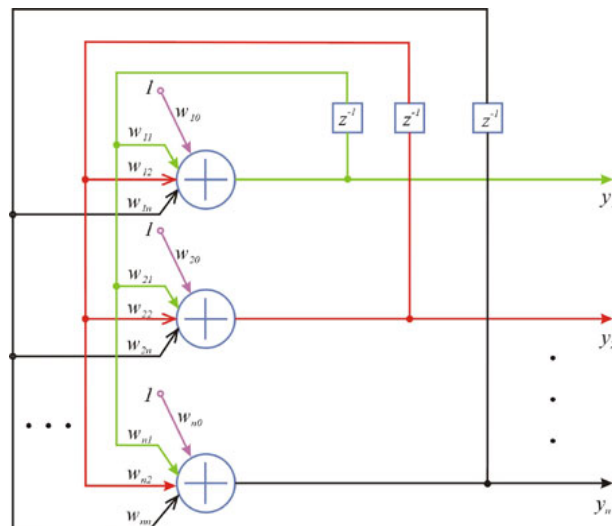


Rysunek 3.3: Przykładowa struktura sieci jednokierunkowej

Źródło: [11]

3.4.2 Sieci rekurencyjne

Ten typ sieci charakteryzuje się występowaniem co najmniej jednego sprzężenia zwrotnego. Taka struktura powoduje, że sygnały wyjściowe warstwy przekazywane są na jej wejście. Oznacza to, że sygnały wejściowe sieci są zależne od bieżącego stanu wejścia oraz od sygnałów wyjściowych z poprzedniego cyklu. Przykładem tego typu sieci może być sieć Hopfielda. Poniższa ilustracja przedstawia przykładową strukturę sieci rekurencyjnej.

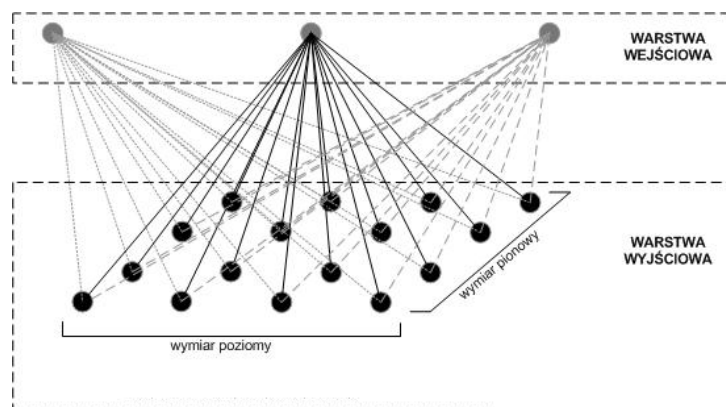


Rysunek 3.4: Przykładowa struktura sieci rekurencyjnej

Źródło: [9]

3.4.3 Sieci komórkowe

Sieci komórkowe charakteryzują się występowaniem sprzężeń wzajemnych między elementami najbliższego sąsiedztwa. Połączenia są zazwyczaj nieliniowe, a największą trudnością w wykorzystywaniu tych sieci jest opracowanie efektywnej i uniwersalnej metody projektowania. Przykładem takiej sieci może być sieć Kohonena. Poniższa ilustracja przedstawia przykładową strukturę sieci komórkowej.



Rysunek 3.5: Przykładowa struktura sieci komórkowej

Źródło: [6]

3.5 Uczenie sieci neuronowych

Część ta poświęcona została objaśnieniu na czym polega proces uczenia sieci, a także pokazaniu, jakie typy uczenia wyróżnia się obecnie. Ponadto do każdego z typów uczenia podano nazwy przykładowych algorytmów. W ich skład wchodzi także metody, które zostały zaimplementowane w ramach pracy dyplomowej. Ich szczegółowy opis znajdzie się jednak w kolejnej części, zatytułowanej "Wybrane algorytmy uczenia nadzorowanego".


3.5.1 Proces uczenia sieci neuronowych

Proces uczenia sprawia, że sieć neuronowa utrwała pewne zachowania poprzez określone doświadczenia. W rozumieniu ogólnym uczenie sztucznej sieci neuronowej polega na wymuszenie na niej pożądanego reagowania na zadane impulsy wejściowe. Najczęściej spotykanym podejściem uczenia sieci jest dostrajanie tak zwanych wag, czyli współczynników liczbowych przypisanych każdemu impulsowi wejściowemu. Zmiana tych współczynników odbywa się iteracyjnie poprzez uczenie nadzorowane lub nienadzorowane. Co ciekawe, większa liczba iteracji nie gwarantuje lepszych rezultatów osiąganych przez sieć. Okazuje się, że może dojść do sytuacji, w której dojdzie to tak zwanego przeuczenia sieci. Z kolei za mała ilość iteracji spowoduje niedouczenie sieci neuronowej. Sprawdzenie tego stosuje się jednak na późniejszym etapie, w procesie weryfikacji, w którym to sieć jest testowana na zbiorze danych testowych.

3.5.2 Uczenie nadzorowane

Uczenie nadzorowane, zwane również uczeniem z nauczycielem polega na tym, że dla każdych danych wejściowych nauczyciel mówi, jaka jest pożądana odpowiedź dla tego sygnału. Korekcje parametrów sieci dokonywane są na podstawie miary błędu, która jest odległością pomiędzy rzeczywistym wyjściem sieci, a pożądaną wartością. Poniższy rysunek przedstawia schemat uczenia nadzorowanego, gdzie kolejne symbole mają następujące oznaczenia:

- x - sygnał wejściowy;
- y - rzeczywista odpowiedź sieci;
- z - pożądana odpowiedź sieci;
- $\delta(z, y)$ - Odległość między rzeczywistą odpowiedzią sieci, a pożądaną odpowiedzią.



Rysunek 3.6: Schemat uczenia nadzorowanego

Źródło: [7]

Zbiór danych wejściowych oraz wyjściowych użytych w procesie uczenia nadzorowanego określany jest zbiorem uczącym. Ten typ uczenia charakteryzuje się dobieraniem wag w taki sposób, aby wyjście sieci w każdej kolejnej iteracji zbliżało się do pożądanej odpowiedzi. Do tej pory powstało wiele algorytmów uczenia nadzorowanego, zarówno dla sieci jedno-, jak i wielowarstwowych. Są to między innymi:

- algorytm wstecznej propagacji błędów;
- metoda gradientów sprzężonych;
- metoda zmiennej metryki (Quasi-Newton);
- metoda paraboloidalnych modeli funkcji błędów (Levenberg – Marquardt).

Wybór metody często nie jest łatwy do wykonania, a każdy przypadek należy rozpatrywać osobno. Często ostateczny wybór algorytmu uczenia ustalany jest na podstawie wielu testów empirycznych.

3.5.3 Uczenie nienadzorowane

Uczenie nienadzorowane, zwane również samouczeniem polega na podawaniu na wejście sieci jedynie przykładowych danych wejściowych. Co ciekawe, odpowiednio zamodelowana sztuczna sieć neuronowa potrafi na podstawie obserwacji sygnałów wejściowych skonstruować algorytm działania polegający na wykrywaniu klas powtarzających się lub bardzo zbliżonych sygnałów wejściowych.


Proces uczenia nienadzorowanego rozpoczyna się od losowego wyznaczenia wag dla każdego neuronu. Następnie do takiej sieci po kolei zaczynają być doprowadzane sygnały wejściowe. Na podstawie składowych tych sygnałów oraz wag neurony określają wartość wyjścia. Sygnały wejściowe oraz ustalone wyjścia sprawiają, że neurony dokonują korekty swoich wag. Zachowanie każdego neuronu podczas korekty determinuje wartość jego sygnału wyjściowego. Jeżeli jest on pozytywny, to wagi są korygowane w taki sposób, że neuron zbliża się do tej klasy obiektu. W odmiennym przypadku, kiedy sygnał ten jest negatywny, wagi będą się zmieniać w taki sposób, że neuron będzie się oddalał od konkretnej klasy. Tak obliczone wagi stają się nowymi wagami neuronów i cały cykl zaczyna się od nowa. Dostatecznie długie trwanie tego procesu sprawi, że powstanie skupisko neuronów, które będzie odpowiedzialne za rozpoznanie konkretnej klasy obiektu. W taki sposób sieć będzie w stanie rozpoznać wszystkie klasy napotkanych obiektów. Przykładowym uczeniem tego typu jest uczenie według zasady Hebba.

3.6 Wybrane algorytmy uczenia nadzorowanego

Niniejszy rozdział został poświęcony algorytmom uczenia nadzorowanego sztucznych sieci neuronowych, które zostały zaimplementowane w ramach pracy dyplomowej. Wszystkie z opisanych metod uczenia odnoszą się do sieci o konkretnej architekturze, a mianowicie są to sieci jednokierunkowe, wielowarstwowe. Algorytmami opisanymi w tym rozdziale są algorytm wstecznej propagacji błędów, metoda gradientów sprzężonych oraz algorytm zmiennej metryki.

3.6.1 Algorytm wstecznej propagacji błędów

Algorytm wstecznej propagacji błędów jest obecnie jednym z najpopularniejszych algorytmów uczenia nadzorowanego sieci jednokierunkowych wielowarstwowych. Pojawił się on w połowie lat 80-tych i odbiło się szerokim echem jego ogłoszenie ze względu na fakt, że do tamtej pory nie znano metody skutecznego uczenia sieci wielowarstwowych. Nazwa algorytmu wzięła się z istoty jego działania, która polega na tym, że wyznaczony błąd $\delta_m^{(j)}$ wyznaczony podczas j -tej iteracji procesu uczenia w neuronie o numerze m podaje się wstecz do przepływu sygnałów, czyli do wszystkich neuronów, które były wejściami dla neuronu o numerze m .



Rysunek 3.7: Schemat sieci realizującej uczenie metodą wstecznej propagacji błędów

Źródło: [12]

Korekcja wag w metodzie wstecznej propagacji błędów odbywa się z wykorzystaniem gradientowych metod optymalizacji. Konkretniej wagi są zmieniane poprzez minimalizację odpowiednio zdefiniowanej funkcji celu $Q(W)$, gdzie wektor W jest wektorem wag poddawanych optymalizacji. Sama funkcja celu najczęściej przyjmuje postać błędu średniokwadratowego, której wzór jest następujący:

$$Q(W) = \frac{1}{2} * \sum_i (z_i - y_i)^2.$$

W algorytmie sztucznej propagacji błędów w każdej kolejnej iteracji wyznacza się kierunek minimalizacji $p(W(d))$, gdzie d oznacza numer iteracji. Najczęściej do wyznaczania tego kierunku używa się metody największego spadku, gdzie kierunek minimalizacji jest zgodny z kierunkiem ujemnego gradientu:

$$p(W) = -\nabla Q(W)$$


Z kolei korekta wag jest dokonywana według wzoru ukazanego poniżej. Symbol η w nim zawarty oznacza współczynnik uczenia.

$$W(j+1) = W(j) + \Delta W,$$

gdzie:

$$\Delta W = -\eta * p(W).$$

W celu lepszego zrozumienia wszystkich wzorów dotyczących uczenia metodą wstecznej propagacji błędów, poniżej zamieszczono ilustrację przedstawiającą sieć neuronową o strukturze dwuwarstwowej z naniesionymi symbolami, które będą występowały we wzorach matematycznych wymienianych w dalszej części.



Rysunek 3.8: Schemat sztucznej sieci neuronowej jednokierunkowej dwuwarstwowej

Źródło: Opracowanie własne

Z powyższego rysunku widać, że j -ta jednostka ukryta otrzymuje sygnał w postaci:

$$e_j = \sum_k w_{jk} * x_k,$$

a na jej wyjściu jest sygnał równy:

$$k_j = \varphi(e_j) = \varphi\left(\sum_k w_{jk} * x_k\right),$$

gdzie φ jest funkcją aktywacji. Z kolei i -ta jednostka wyjściowa na wejściu otrzymuje sygnał równy:

$$e_i = \sum_j v_{ij} * k_j = \sum_j v_{ij} * \varphi\left(\sum_k w_{jk} * x_k\right),$$

a na jej wyjściu wartość sygnału jest równa:

$$y_i = \varphi(e_i) = \varphi\left(\sum_j v_{ij} * k_j\right) = \varphi\left(\sum_j v_{ij} * \varphi\left(\sum_k w_{jk} * x_k\right)\right).$$

Po podstawieniu do wzoru na miarę błędu, który został już opisany w niniejszym rozdziale, otrzymywany jest następujący rezultat:

$$Q(W) = \frac{1}{2} * \sum_i (z_i - \varphi(\sum_j v_{ij} * \varphi(\sum_k w_{jk} * x_k)))^2.$$

Korzystając z reguły spadku gradientu można obliczyć Δv_{ij} konieczną do uzyskania wag pomiędzy jednostkami ukrytymi, a wyjściowymi:

$$\Delta v_{ij} = -\eta * \frac{\partial Q}{\partial v_{ij}} = \eta * \sum (z_i - y_i) * \varphi'(e_i) * k_j = \eta * \sum \delta_i * k_j.$$

W podobny sposób należy obliczyć wagi Δw_{jk} , która zostanie wykorzystana do obliczenia wag między jednostkami wejściowymi, a ukrytymi:

$$\begin{aligned} \Delta w_{jk} &= -\eta * \frac{\partial Q}{\partial w_{jk}} = -\eta * \sum \frac{\partial Q \partial k_j}{\partial k_j \partial w_{jk}} = \\ &= \eta * \sum (z_i - y_i) * \varphi'(e_i) * v_{ij} * \varphi'(e_j) * x_k = \\ &= \eta * \sum_i \delta_i * v_{ij} * \varphi'(e_j) * x_k = \eta * \sum \delta_j * x_k. \end{aligned}$$

Jak widać z powyższych przekształceń, to w jaki sposób liczony jest błąd δ zależy od rozpatrywanej warstwy. Dla ostatniej warstwy połączeń był on równy:

$$\delta = (z_i - y_i) * \varphi'(e_i),$$

z kolei dla wszystkich pozostałych połączeń jego postać była następująca:

$$\delta = \varphi'(e_j) * \sum_i \delta_i * v_{ij}.$$

Błędy są mnożone przez dokładnie te same współczynniki wag, przez które były przemnażane przesyłane sygnały. Zmianą natomiast jest kierunek przesyłu informacji, który został odwrócony i jest zwrócony od wyjścia do wejścia.

3.6.2 Algorytm zmiennej metryki

Ze względu na fakt, że uczenie metodą wstecznej propagacji błędów często jest procesem czasochłonnym, zdecydowano się na prowadzenie badań nad metodami opartymi na algorytmach gradientowych, co pozwoliło przyspieszyć uczenie. Algorytmy te bazują na rozwinięciu w szereg Taylora funkcji celu $Q(W)$ w pobliżu znanego rozwiązania W . Jednym z takich algorytmów jest algorytm zmiennej metryki. W metodzie tej stosuje się kwadratowe przybliżenie funkcji $Q(W)$ w pobliżu znanego rozwiązania $W^{(j)}$:

$$Q(W^{(j)} + p^{(j)}) \approx Q(W^{(j)}) + [g(W^{(j)})]^T * p^{(j)} + \frac{1}{2} * p^{(j)T} * H(W^{(j)}) * p^{(j)} + O(h^3),$$

gdzie:

$$g(W) = \delta Q = [\frac{\partial Q}{\partial w_1}, \frac{\partial Q}{\partial w_2}, \dots, \frac{\partial Q}{\partial w_n}]$$

jest gradientem funkcji celu, a

$$H(W) = \begin{bmatrix} \frac{\partial Q}{\partial w_1 \partial w_1} & \dots & \frac{\partial Q}{\partial w_n \partial w_1} \\ \frac{\partial Q}{\partial w_1 \partial w_n} & \dots & \frac{\partial Q}{\partial w_n \partial w_n} \end{bmatrix}$$

jest macierzą drugich pochodnych (hesjan), w której: p oznacza wektor kierunkowy wyznaczany w celu poszukiwania minimum, a $O(h^3)$ jest błędem obcięcia szeregu.

Punkt rozwiązania $W = W^{(j)}$, gdzie j jest wskaźnikiem oznaczającym wartość zmiennych obliczonych w j -tym kroku, jest optymalnym punktem funkcji $Q(W)$, jeśli $g(W^{(j)}) = 0$. Z tego względu minimum funkcji wymaga, aby:

$$\frac{\partial Q(W^{(j)} + p)}{\partial p} = 0.$$

Po zróżniczkowaniu otrzymywane jest:

$$g(W^{(j)}) + H(W^{(j)}) * p^{(j)} = 0.$$

Z powyższego wzoru wynika, że:

$$p^{(j)} = -[H(W^{(j)})]^{-1} * g(W^{(j)}).$$

Powyższe równanie pozwala na wyznaczenie kierunku $p^{(j)}$, który zapewni minimum funkcji celu. Do jego obliczenia należy w każdym kroku znaleźć wartość gradientu g oraz hesjanu H w punkcie $W^{(j)}$. Warunkiem, który może okazać się trudny do spełnienia jest fakt, że w każdym cyklu hesjan musi być dodatni. Rozwiązaniem tego problemu jest stosowanie przybliżenia $G(W^{(j)})$. W metodzie zmiennej metryki hesjan modyfikowany jest w każdym kroku w taki sposób, aby aktualna wartość hesjanu $G(W^{(j)})$ przybliżała krzywiznę funkcji celu Q zgodnie z zależnością:

$$G(W^j)(W^{(j)} - W^{(j-1)}) = g(W^{(j)}) - g(W^{(j-1)}).$$

Do wad tej metody z pewnością można zaliczyć stosunkowo dużą złożoność obliczeniową oraz duże wymagania w stosunku do pamięci przy przechowywaniu macierzy hesjanu. Mimo wad wyżej wymienionych algorytm ten jest jednym z najczęściej stosowanych do uczenia sieci neuronowych jednokierunkowych ze względu na jego szybką zbieżność oraz stosunkowo prostą implementację.

3.6.3 Algorytm gradientów sprzężonych

W porównaniu z wcześniej opisywaną metodą (tj. algorytmu zmiennej metryki), w algorytmie gradientów sprzężonych rezygnuje się z wykorzystania informacji o macierzy hesjanu, która była wykorzystywana do konstrukcji kierunku poszukiwań minimum. W tej metodzie nowy kierunek $p^{(j)}$ wyznacza się tak, by był on sprzężony ze wszystkimi poprzednimi kierunkami $p^{(0)}, p^{(1)}, p^{(2)}, \dots, p^{(j-1)}$. Wzór na wyznaczenie kierunku $p^{(j)}$ ma następującą postać:

$$p^{(j)} = -g(W^{(j)}) + \sum_{m=0}^{j-1} \beta_m^{(j)} * p_m,$$

gdzie $g(W^{(j)})$ to aktualna wartość wektora gradientu, a $\beta^{(j)}$ to współczynnik sprzężenia. Sumowanie, które widoczne jest we wzorze dotyczy wszystkich poprzednich kierunków. Algorytm ten dzięki małej złożoności obliczeniowej pozwala na rozwiązanie niezwykle dużych problemów optymalizacyjnych i można go stosować przy liczbie zmiennych sięgających nawet kilkudziesięciu tysięcy. Jak widać w powyższym wzorze nowy kierunek zależy od gradientu funkcji celu, a także od poprzedniego kierunku pomnożonego przez współczynnik sprzężenia. Obecnie znanych jest wiele metod doboru współczynnika β . Najpopularniejsze z nich to:

- metoda Fletchera-Reevesa;
- metoda Polaka-Ribiere’a;
- metoda Dai-Yuan’a;
- metoda Liu-Storey’a.

Po wyznaczeniu $p^{(j)}$ można przejść do korekcji wag, co się odbywa w następujący sposób:

$$W^{(j+1)} = W^{(j)} + \eta * p^{(j)},$$

gdzie η oznacza współczynnik uczenia. Dobór tego współczynnika w tej metodzie jest szczególnie istotny. Należy go wyznaczyć w taki sposób, aby punkt $W^{(j+1)}$ leżał jak najbliżej minimum funkcji celu $Q(W)$ na kierunku $p^{(j)}$. Przyjęcie zbyt małej wartości parametry η spowoduje, że proces uczenia będzie trwał bardzo długo ze względu na niewykorzystanie możliwości zminimalizowania wartości funkcji celu w danej iteracji. Z kolei za duży współczynnik uczenia może spowodować przeskoczenie minimum funkcji celu.

Rozdział 4

Implementacja aplikacji komputerowej

W ramach pracy dyplomowej miał zostać zaimplementowany program służący do diagnostyki raka piersi u kobiet. Niniejszy rozdział jest właśnie mu dedykowany. Znajdą się w nim informacje opisujące aplikację wykonaną w ramach pracy dyplomowej, a ponadto opisany w nim zostanie język programowania, jaki wykorzystano do stworzenia aplikacji, a także biblioteki oraz inne narzędzia, które były przydatne przy pracy nad nią. Ponadto w rozdziale tym znajdują się informacje, w jaki sposób należy uruchomić aplikację i jak można ją parametryzować.

4.1 Opis wykorzystanych narzędzi

Część ta poświęcona jest głównie narzędziom, jakie zostały wykorzystane w trakcie implementacji aplikacji służącej do diagnozowania rodzaju nowotworu raka piersi z użyciem sieci neuronowej. Na początku zostanie przedstawiony język Python, w którym program został napisany. Następnie zaprezentowane zostaną wykorzystane biblioteki, a także system kontroli wersji GIT, który był niezwykle przydatny w trakcie pracy nad aplikacją.

4.1.1 Język Python

Język Python został wybrany do implementacji aplikacji komputerowej ze względu na szereg jego zalet. Przede wszystkim jego głównym atutem jest fakt, że kod pisany w tym języku jest niezwykle czytelny, a ponadto składnia języka sprawia, że jest stosunkowo zwężły. Prostota języka objawia się między innymi w dostępie do struktur danych, gdzie bez żadnych zaawansowanych bibliotek programista ma dostęp do takich struktur jak lista, tupla, czy też słownik. Dużym plusem Pythona jest także fakt, że wspiera on różne paradygmaty programowania, między innymi obiektowy, imperatywny, a także funkcyjny. Dodatkowo warto zwrócić uwagę, że język ten jest niezwykle popularny i dostępny na licencji open-source. Takie rozwiązanie sprawia, że jest on coraz powszechniej stosowany, a ponadto powstaje duża ilość kolejnych zewnętrznych bibliotek, co przekłada się na rozwój języka i łatwość w jego wykorzystywaniu. Co ważne język Python jest jednym z prostszych języków programowania. Typowanie odbywa się w sposób automatyczny, a z kolei za zarządzanie pamięcią odpowiada garbage collector. Te cechy sprawiają, że rozpoczęcie pisania kodu w tym języku jest niezwykle proste i można przystąpić do pisania użytkowych programów w niezwykle krótkim czasie. Należy jednak zwrócić uwagę, że Przez fakt iż duża część czynności odbywa się automatycznie to też wydajność aplikacji może być nieco niższa w porównaniu z językami kompilowanymi, takimi jak chociażby C++, czy Java.

Powstanie Pythona szacuje się na wczesne lata 90-te, a jego głównym twórcą jest Guido van Rossum. Największą popularność temu językowi przyniosła wydana w 2000 roku wersja 2.0. Obecnie jednak najpowszechniej stosowaną wersją Pythona jest wersja trzecia, która została wydana w 2008 roku i co ciekawe wraz z wydaniem wersji trzeciej została zerwana kompatybilność wstecz. Istnieje jednak narzędzie "2to3" stworzone do przetłumaczenia kodu napisanego w Pythonie 2 na Pythona 3. Inne narzędzie "3to2" robi dokładnie to samo, z tym, że w drugą stronę. W aplikacji napisanej w ramach pracy dyplomowej została wykorzystana wersja 3.5.2, która została wydana 27.06.2016.

Pisanie kodu w języku Python wymaga zainstalowanego interpretera, którego zadaniem jest tłumaczenie wysokopoziomowych instrukcji na kod maszynowy w trakcie działania programu. Stanowi on swego rodzaju łącznik między językiem programowania, a systemem operacyjnym, który pozwala tworzyć różnego typu aplikacje bez względu na platformę. Wspomniany interpreter jest dostępny dla większości popularnych systemów operacyjnych, między innymi Linux, Windows, czy Mac OS X.

4.1.2 Biblioteki zewnętrzne

Niniejsza część opisuje wykorzystane biblioteki oraz pakiety, które wykorzystano w ramach pracy nad programem. Jak już wcześniej wspomniano język Python jest niezwykle popularny i powszechnie wykorzystywany przez programistów z całego świata. Dzięki temu powstaje wiele specjalistycznych bibliotek zewnętrznych, które ułatwiają w znaczny sposób rozwiązywanie specjalistycznych zagadnień i problemów. Część z nich została wykorzystana do stworzenia aplikacji diagnozującej raka piersi, a poniżej znajdują się opisy każdego z wykorzystanych pakietów.

Pakiet Numpy

Pakiet Numpy jest jednym z podstawowych zestawów narzędzi, z którego można skorzystać w języku Python. Umożliwia on wykonywanie zaawansowanych obliczeń matematycznych między innymi: mnożenie, dodawanie, odwracanie, czy też transponowanie macierzy, ale także. Numpy udostępnia specjalizowane typy danych oraz funkcje, które nie znajdują się w standardowej bibliotece języka Python. Podstawowym, a zarazem najważniejszym obiektem w tym pakiecie jest klasa ndarray wprowadzająca obiekty array. Obiekty te traktuje się jako kontenery na dane w postaci macierzy lub wektorów. W porównaniu do standardowej listy lub krotki, którą udostępnia Python jest wiele różnic, gdzie część z nich wymieniono poniżej:

- obiekty znajdujące się w macierzy muszą być tego samego typu;
- obiekty array zachowują swój rozmiar. W przypadku jego zmiany powstaje nowy obiekt, a stary zostaje usunięty;
- obiekty array posiadają wiele metod, które operują na danych przechowywanych w obiekcie. Metody te są specjalistycznie optymalizowane, aby nadawały się do operacji na dużej ilości danych.

Poniżej zostały zaprezentowane fragmenty kodu, które obrazują działanie pakietu Numpy:

```
1 import numpy
2
3 array = numpy.arange(6) # stworzenie tablicy z wartościami od 0 do 5
4 print(array) # [0 1 2 3 4 5]
```



```
5
6 reshaped_array = numpy.reshape(array , (2, 3)) # zmiana kształtu macierzy
  bez zmiany jej danych
7 print(reshaped_array) # [[0 1 2]
8                        # [3 4 5]]
9
10 dim_reshaed_array = numpy.ndim(reshaped_array) # liczba wymiarow macierzy
11 print(dim_reshaed_array) # 2
12
13 shape = reshaped_array.shape # kształt macierzy
14 print(shape) # (2, 3)
15
16 data_type = reshaped_array.dtype # typ danych w macierzy
17 print(data_type) # int64
18
19 new_array = reshaped_array + 3 # dodanie do kazdego elementu macierzy
  liczby 3
20 print(new_array) # [[3 4 5]
21                  # [6 7 8]]
22
23 new_array = reshaped_array * 3 # przemnozenie wszystkich elementow macierzy
  przez 3
24 print(new_array) # [[ 0  3  6]
25                  # [ 9 12 15]]
26
27 new_array = reshaped_array ** 2 # potegowanie wszystkich elementow macierzy
28 print(new_array) # [[ 0  1  4]
29                  # [ 9 16 25]]
30
31 condition_result = reshaped_array > 2 # sprawdzenie , ktore elementy
  macierzy sa wieksze od 2
32 print(condition_result) # [[False False False]
33                          # [ True  True  True ]]
34
35 array[array > 2] = 5 # podmiana elementow wiekszych od 2 na 5
36 print(array) # [0 1 2 5 5 5]
37
38 new_arr = [1, 2, 3]
39 result = numpy.exp(new_arr) # exponenta wszyztskich elementow
40 print(result) # [ 2.71828183  7.3890561  20.08553692]
41
42 new_arr = [1, 2, 3]
43 result = numpy.sqrt(new_arr) # pierwiastek wszyztskich elementow
44 print(result) # [1. 1.41421356 1.73205081]
45
46 first_array = [1, 2, 3]
47 second_array = [4, 5, 6]
48 result = numpy.dot(first_array , second_array) # iloczyn skalarny dwoch
  wektorow
49 print(result) # 32
50
51 first_array = [[1, 2], [3, 4]]
52 second_array = [[5, 6], [7, 8]]
53 result = numpy.add(first_array , second_array) # dodawanie macierzy
54 print(result) # [[ 6  8]
55               # [10 12]]
```

Pakiet Pandas

Pakiet Pandas jest biblioteką, którą można wykorzystać w języku Python do analizy danych. Udostępnia ona szereg operacji oraz funkcji związanych z analizą danych. Pierwszą z najbardziej przydatnych funkcji jest możliwość wczytywania plików z wielu różnych źródeł, między innymi z pliku ".csv", co też zostało wykorzystane w wykonanej aplikacji. Co ciekawe plik ten wcale nie musi się znajdować lokalnie na dysku komputera, a można go pobierać z serwera. To powoduje, że wczytanie danych w aplikacji komputerowej wygląda w następujący sposób:

```
1 import pandas
2
3 data_frame = pandas.read_csv('https://archive.ics.uci.edu/ml/machine-learning-databases/breast-cancer-wisconsin/breast-cancer-wisconsin.data')
```

Pakiet pandas ponadto oferuje o wiele bardziej zaawansowane metody do przetwarzania danych, a część z nich można zobaczyć we fragmentach kodu znajdujących się poniżej:

```
1 import pandas
2 csv_url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/breast-cancer-wisconsin/breast-cancer-wisconsin.data'
3 data_frame = pandas.read_csv(csv_url) # wczytanie pliku csv
4
5 instances_number = data_frame.shape[0] # pobranie liczby wszystkich instancji
6
7 columns_number = data_frame.shape[1] # pobranie liczby kolumn
8
9 data_frame.select_dtypes(['object']) # pobranie wszystkich wierszy, w których co najmniej jedna wartość jest typu object
10
11 data_frame.apply(pandas.to_numeric) # przekonwertowanie wszystkich wartości w zbiorze na liczby
12
13 data_frame['nazwa_kolumny'].unique() # pobranie unikalnych wartości spod wskazanej kolumny
14
15 data_frame.iloc[0:instances_number, [1, 2, 3]].values # pobranie wybranych kolumn (1, 2, 3) spośród wszystkich instancji
```

Pakiet Scikit-learn

Biblioteka scikit-learn jest ogromną bazą zawierającą implementację niezwykle dużej ilości algorytmów potrzebnych do pracy z uczeniem maszynowym w Pythonie. Jej wielkim atutem jest fakt, że posiada licencję open-source przez co korzystanie z niej jest całkowicie darmowe. Pakiet ten jest systematycznie rozwijany, a jego twórcy ściśle podążają za ustalonymi konwencjami. Pomimo wielu metod i algorytmów, jakie oferuje biblioteka w aplikacji powstałej w ramach pracy dyplomowej wykorzystano jedynie funkcje służące do przygotowania danych przed rozpoczęciem procesu uczenia sieci neuronowej. Były to:

- `fit_transform` - normalizuje etykiety i transformuje je z wartości nienumerycznych na numeryczne;
- `train_test_split` - dzieli zbiór danych na zbiór trenujący i testujący.

4.1.3 Wirtualne środowisko

Wirtualne środowisko Pythona to niezwykle przydatne narzędzie do tworzenia różnego rodzaju projektów. Aplikacje pisane w Pythonie przy użyciu rozbudowanych frameworków formuje się najczęściej właśnie w środowisku wirtualnym, co pozwala na instalację tych samych bibliotek w różnych wersjach wymaganych przez dany projekt w każdym momencie. Wirtualne środowisko stosuje się także w celu łatwiejszego testowania oraz utrzymania porządku w bibliotekach wykorzystywanych w aplikacji.

Wirtualne środowisko w praktyce jest niczym innym, jak folderem, do którego wgrzana jest wymagana wersja interpretera i narzędzia pip, za pomocą którego instalujemy potrzebne biblioteki, pakiety oraz moduły. Tworzy je się za pomocą narzędzia virtualenv, poprzez wpisane w terminalu:

```
$ virtualenv nazwa_katalogu_ze_srodowiskiem.
```

Po jego utworzeniu należy je aktywować poprzez wywołanie:

```
$ source virtualenv nazwa_katalogu_ze_srodowiskiem/bin/activate.
```

Po jego aktywacji każdy użytkownik może za pomocą instalatora pakietów dodawać do środowiska wirtualnego kolejne biblioteki i co ważne, nie wymaga to uprawnień administratora. W celu zainstalowania potrzebnej biblioteki wystarczy wpisać:

```
$ pip install nazwa_pakietu.
```

W przypadku chęci użytkownika utworzenia pliku tekstowego ze wszystkimi nazwami bibliotek oraz ich wersjami, musi wpisać zaledwie:

```
$ pip freeze > nazwa_pliku_z_zaleznosciami .
```

Po stworzeniu takiego pliku można przenieść aplikację na dowolny inny komputer i będzie możliwa ona do uruchomienia po stworzeniu na niej wirtualnego środowiska i zainstalowaniu bibliotek z pliku za pomocą komendy:

```
$ pip install -r nazwa_pliku_z_zaleznosciami .
```

Jak widać, praca z wirtualnym środowiskiem nie jest w żaden sposób skomplikowana, a przynosi wiele korzyści. Zdecydowanie największą z nich jest łatwa przenośność projektu, a także możliwość powrotu do wieloletnich projektów, dawno odłożonych na bok, do których wersje wykorzystanych bibliotek są zapisane w jednym pliku. Bez korzystania z wirtualnego środowiska starsze aplikacje mogłyby być niemożliwe do uruchomienia ze względu np. na brak kompatybilności wstecz co niektórych pakietów.

4.1.4 System kontroli wersji GIT

System kontroli wersji to rodzaj oprogramowania, za pomocą którego można śledzić zmiany w kodzie. Jedną z ważniejszych jego funkcjonalności jest także pomoc w łączeniu zmian dokonanych w tych samych plikach przez wiele osób. Obecnie na rynku najbardziej powszechne są dwa systemy kontroli wersji: svn oraz GIT i to z pomocą tego drugiego powstawała aplikacja wykonywana w ramach pracy dyplomowej. Pierwsza wersja GITa powstała w 2005 roku, a za jego twórcę uważa się Linusa Torvaldsa - człowieka, który wcześniej stworzył jądro systemu Linux. Git jest powszechnie używanym systemem, a co ważniejsze także darmowym. Obecnie wiele projektów korporacyjnych, jak na przykład Android korzysta z tego oprogramowania. Do najważniejszych cech systemu GIT należy:

- lokalne wykonywanie większości operacji (do korzystania nie jest niezbędne łącze internetowe);
- duża szybkość działania (szybkie zarówno wysyłanie zmian na serwer, jak i ich pobieranie)
- łatwość rozgałęzienia i łączenia kodu;
- możliwość obsługi zarówno małych i dużych projektów.
- obecność wsparcia dla wielu protokołów sieciowych (HTTP, FTP, SSH);
- każda rewizja jest obrazem całego projektu.

W celu przybliżenia funkcjonalności systemu GIT poniżej zostały wymienione i opisane najczęściej przydające się komendy w trakcie pracy nad projektem:

- **git init** - zainicjowanie nowego repozytorium w obecnym katalogu;
- **git add [nazwa pliku]** - dodanie pliku do repozytorium i sprawienie, że zmiany w nim zaczną być śledzone;
- **git commit** - zatwierdzenie zmian w zmienionych plikach;
- **git push** - wysłanie zmian na serwer;
- **git checkout [nazwa rozgałęzienia]** - przełączenie z aktywnego rozgałęzienia na wybrane przez użytkownika;
- **git checkout -b [nazwa rozgałęzienia]** - tworzenie nowego rozgałęzienia z obecnego i przełączenie się na niego;
- **git pull** - pobranie najnowszych zmian z serwera;
- **git status** - wyświetlenie wszystkich zmienionych plików i ich statusów (nowo dodany, zmodyfikowany, usunięty);
- **git diff [nazwa pliku]** - wyświetlenie wszystkich zmian w plikach.

4.2 Opis działania programu

Uruchomienia programu jest możliwe dopiero po aktywacji wirtualnego środowiska, co zostało dokładnie opisane w wcześniejszej części pracy. Po jego aktywacji użytkownik może swobodnie uruchomić plik wykonywalny, który nazywa się "main.py" używając komendy:

python3 main.py.

Po uruchomieniu programu w taki sposób, zostanie on uruchomiony z domyślnymi wartościami parametrów. Użytkownik ma możliwość zapoznania się ze wszelkimi argumentami, z jakimi może uruchomić aplikację poprzez wpisanie:

python3 main.py --help

lub

python3 main.py -h.

Po uruchomieniu wyżej wymienionej komendy, użytkownik dostaje zbiór pełnych informacji o programie:

```
(env) szaba@szaba-Lenovo-G510:~/Documents/studia/mgr/src(master)$ python3 main.py -h
Program to test supervised learning in neural networks. User can do tests based on database "breast-cancer-wisconsin",
which is taken from ics.uci repository. User can manipulate parameters, which are described below.
options:
  -h | --help - display help
  -a | --algorithm_name <algorithm_name> - learning algorithm (possible: GradientDescent, ConjugateGradient, LevenbergMarquardt), default: LevenbergMarquardt
  -s | --test_size <test_size> - the percentage size of the test set (range from 0.1 to 0.9), default: 0.4
  -l | --learning_rate <learning_rate> - learning rate (range from 0.01 to 0.99), default: 0.1
  -e | --epochs_number <epochs_number> - epochs number, must be integer greater than 0, default: 100
  -u | --hidden_units_number <hidden_units_number> - hidden units number in neural network, must be integer greater than 0, default: 3
  -i | --hidden_layers_number <hidden_layers_number> - hidden layers number in neural network, must be integer greater than 0, default: 1
Author:
  Written by Sławomir Zaba
```

Rysunek 4.1: Pokazanie wszystkich aplikacji o programie.

Źródło: Własne

Jak widać z powyższej ilustracji, aplikację można sparametryzować poprzez sześć różnych opcji opisanych poniżej:

Lp.	Pełna nazwa argumentu	Skrócona nazwa argumentu	Opis argumentu	Wartość domyślna	Zakres możliwych wartości
1	--algorithm_name	-a	Nazwa algorytmu wybranego do uczenia sieci	QuasiNewton	GradientDescent, ConjugateGradient, QuasiNewton
2	--test_size	-s	Określenie rozmiaru zbioru testowego	0.4	[0.1, 0.9]
3	--learning_rate	-l	Określenie współczynnika uczenia (ma znaczenie tylko dla algorytmów, w których wykorzystuje się współczynnik uczenia)	0.1	[0.01, 0.99]
4	--epochs_number	-e	Liczba epok	100	Wszystkie liczby naturalne
5	--hidden_units_number	-u	Liczba neuronów w warstwach ukrytych	3	Wszystkie liczby naturalne
6	--hidden_layers_number	-i	Liczba warstw ukrytych	1	Wszystkie liczby naturalne

Tabela 4.1: Opis możliwych parametrów przy egzekucji programu.

Mając do dyspozycji pełną wiedzę o dostępnych parametrach aplikacji, użytkownik może ją uruchomić w prosty sposób, czego przykład widać na poniżej ilustracji:

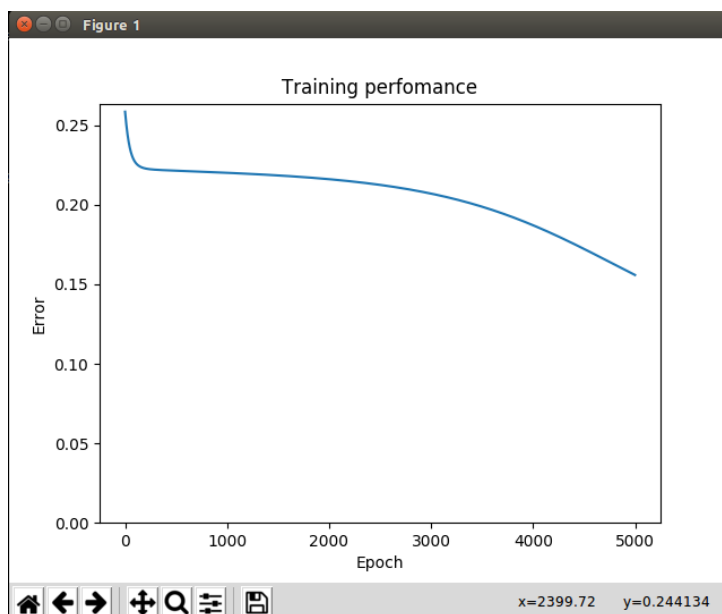
```
(env) szaba@szaba-Lenovo-G510:~/Documents/studia/mgr/src(master)$ python3 main.py -e 5000 -s 0.2 -a GradientDescent -l 0.1
program executed with params:
  algorithm_name: GradientDescent,
  test_size: 0.2,
  learning_rate: 0.1,
  epochs_number: 5000,
  hidden_units_number: 3
  hidden_layers_number: 1
correctly classified: 116
wrongly classified: 21
percent correct: 84.67
confusion matrix:
[[40  3]
 [18 76]]
sensitivity: 0.69
specifity: 0.96
precision: 0.93
```

Rysunek 4.2: Przykładowe działania uruchomionej aplikacji.

Źródło: Własne

Jak można zauważyć aplikacja w pierwszym kroku podaje wszystkie parametry, z jakimi została uruchomiona. Kolejno po nauczaniu sieci wskazanym algorytmem, testuje

ją i zwraca informacje na temat ilości poprawnych i niepoprawnych klasyfikacji, a także obrazuje macierz błęd oraz wyliczone na jej podstawie takie właściwości jak wrażliwość, swoistość oraz precyzja. Dodatkowo aplikacja po zakończeniu działania pokazuje wykres obrazujący, jak zmieniała się wartość błęd w trakcie uczenia, co można zaobserwować na poniższej ilustracji:



Rysunek 4.3: Przykładowy wykres rysowany przez aplikację, który pokazuje jak zmieniała się wartość błęd w trakcie uczenia sieci.

Źródło: Własne

Rozdział 5

Wyniki eksperymentów

Niniejszy rozdział poświęcony jest wynikom eksperymentów, jakie przeprowadzono w ramach pracy dyplomowej. Badania miały na celu porównać jakość wybranych algorytmów uczenia nadzorowanego sieci neuronowych. Zdecydowano, że analiza zostanie przeprowadzona na trzech różnych architekturach sieci: z jedną, trzema i pięcioma warstwami ukrytymi. W każdej z architektur liczba neuronów w warstwie ukrytej wynosiła trzy. Wielkość zbioru uczącego została ustalona na poziomie 30% całego zbioru danych. Ponadto w badaniach starano się znaleźć optymalne parametry uczenia dla każdego z algorytmów, tak aby sieć wykazywała się najlepszą jakością klasyfikacji. W tym celu wykorzystywane były różne modyfikacje parametrów, takich jak liczba epok i współczynnik uczenia. Aby mieć lepszy obraz na wyniki uzyskiwane przez sieć, każde badanie powtórzono cztery razy.

5.1 Algorytm wstecznej propagacji błędów

W części tej zobrazowano wyniki badań dla algorytmu wstecznej propagacji błędów. W metodzie tej parametrami, jakie były zmieniane w celu określenia najlepszej jakości uczenia była liczba epok oraz współczynnik uczenia.

Sieć składająca się z jednej warstwy ukrytej

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja					
10	0.01	546.39	127	78	61.95
10	0.2	305.4	127	78	61.95
10	0.4	310.07	127	78	61.95
10	0.6	304.14	127	78	61.95
10	0.9	300.15	127	78	61.95
20	0.01	295.93	127	78	61.95
20	0.2	298.78	61	144	29.76
20	0.4	295.62	127	78	61.95
20	0.6	298.28	127	78	61.95
20	0.9	1838.18	127	78	61.95
50	0.01	309.5	78	127	38.05
50	0.2	313.24	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50	0.4	310.25	127	78	61.95
50	0.6	304.84	127	78	61.95
50	0.9	307.46	127	78	61.95
100	0.01	326.34	119	86	58.05
100	0.2	325.84	127	78	61.95
100	0.4	319.94	127	78	61.95
100	0.6	336.02	127	78	61.95
100	0.9	331.62	127	78	61.95
200	0.01	361.14	127	78	61.95
200	0.2	363.79	127	78	61.95
200	0.4	362.75	127	78	61.95
200	0.6	355.34	127	78	61.95
200	0.9	361.99	127	78	61.95
500	0.01	452.66	127	78	61.95
500	0.2	453.08	127	78	61.95
500	0.4	449.15	127	78	61.95
500	0.6	453.15	127	78	61.95
500	0.9	453.89	153	52	74.63
1000	0.01	608.91	127	78	61.95
1000	0.2	602.64	127	78	61.95
1000	0.4	602.82	147	58	71.71
1000	0.6	612.61	136	69	66.34
1000	0.9	612.4	174	31	84.88
2000	0.01	918.42	127	78	61.95
2000	0.2	904.21	127	78	61.95
2000	0.4	954.06	176	29	85.85
2000	0.6	919.47	175	30	85.37
2000	0.9	910.73	176	29	85.85
5000	0.01	1833.74	127	78	61.95
5000	0.2	1819.79	172	33	83.9
5000	0.4	1875.42	178	27	86.83
5000	0.6	1830.06	178	27	86.83
5000	0.9	2929.03	177	28	86.34
10000	0.01	4057.23	127	78	61.95
10000	0.2	4132.36	177	28	86.34
10000	0.4	4502.97	177	28	86.34
10000	0.6	3751.62	177	28	86.34
10000	0.9	4229.5	177	28	86.34
20000	0.01	6530.84	127	78	61.95
20000	0.2	6582.96	177	28	86.34
20000	0.4	6685.04	177	28	86.34
20000	0.6	6552.18	177	28	86.34
20000	0.9	6606.48	178	27	86.83
50000	0.01	15890.95	134	71	65.37

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50000	0.2	16033.5	177	28	86.34
50000	0.4	16051.75	179	26	87.32
50000	0.6	15902.31	179	26	87.32
50000	0.9	16152.83	182	23	88.78
Druka iteracja					
10	0.01	580.89	78	127	38.05
10	0.2	299.42	127	78	61.95
10	0.4	295.5	127	78	61.95
10	0.6	301.83	127	78	61.95
10	0.9	294.87	127	78	61.95
20	0.01	285.95	78	127	38.05
20	0.2	289.69	127	78	61.95
20	0.4	1814.08	127	78	61.95
20	0.6	305.18	127	78	61.95
20	0.9	297.78	127	78	61.95
50	0.01	298.19	127	78	61.95
50	0.2	300.02	127	78	61.95
50	0.4	306.7	127	78	61.95
50	0.6	297.84	127	78	61.95
50	0.9	297.72	127	78	61.95
100	0.01	323.3	127	78	61.95
100	0.2	320.7	127	78	61.95
100	0.4	318.4	127	78	61.95
100	0.6	316.36	127	78	61.95
100	0.9	326.03	127	78	61.95
200	0.01	350.95	127	78	61.95
200	0.2	361.17	127	78	61.95
200	0.4	347.99	127	78	61.95
200	0.6	349.45	127	78	61.95
200	0.9	359.15	127	78	61.95
500	0.01	436.44	127	78	61.95
500	0.2	446.39	127	78	61.95
500	0.4	439.82	127	78	61.95
500	0.6	448.18	127	78	61.95
500	0.9	438.54	132	73	64.39
1000	0.01	593.31	127	78	61.95
1000	0.2	597.21	127	78	61.95
1000	0.4	589.29	171	34	83.41
1000	0.6	602.09	169	36	82.44
1000	0.9	601.97	175	30	85.37
2000	0.01	898.55	127	78	61.95
2000	0.2	897.06	167	38	81.46
2000	0.4	893.8	171	34	83.41
2000	0.6	894.5	178	27	86.83

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
2000	0.9	897.73	178	27	86.83
5000	0.01	2789.26	127	78	61.95
5000	0.2	1855.11	173	32	84.39
5000	0.4	1847.99	178	27	86.83
5000	0.6	1844.27	179	26	87.32
5000	0.9	1850.58	177	28	86.34
10000	0.01	3381.25	127	78	61.95
10000	0.2	3410.91	178	27	86.83
10000	0.4	3414.15	177	28	86.34
10000	0.6	3380.46	177	28	86.34
10000	0.9	3382.29	178	27	86.83
20000	0.01	6441.7	127	78	61.95
20000	0.2	6463.72	178	27	86.83
20000	0.4	6507.34	177	28	86.34
20000	0.6	6497.1	179	26	87.32
20000	0.9	6473.73	177	28	86.34
50000	0.01	15808.88	171	34	83.41
50000	0.2	15805.29	176	29	85.85
50000	0.4	15678.14	179	26	87.32
50000	0.6	15664.21	181	24	88.29
50000	0.9	15626.86	183	22	89.27
Trzecia iteracja					
10	0.01	641.9	77	128	37.56
10	0.2	291.72	78	127	38.05
10	0.4	296.08	127	78	61.95
10	0.6	292.63	127	78	61.95
10	0.9	293.36	127	78	61.95
20	0.01	291.95	78	127	38.05
20	0.2	297.22	127	78	61.95
20	0.4	293.97	127	78	61.95
20	0.6	290.96	127	78	61.95
20	0.9	295.47	127	78	61.95
50	0.01	305.22	127	78	61.95
50	0.2	311.85	127	78	61.95
50	0.4	308.79	127	78	61.95
50	0.6	307.31	127	78	61.95
50	0.9	313.9	127	78	61.95
100	0.01	326.84	78	127	38.05
100	0.2	330.0	127	78	61.95
100	0.4	332.73	127	78	61.95
100	0.6	324.92	127	78	61.95
100	0.9	328.77	127	78	61.95
200	0.01	353.71	127	78	61.95
200	0.2	1879.76	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
200	0.4	373.35	127	78	61.95
200	0.6	364.44	127	78	61.95
200	0.9	377.05	127	78	61.95
500	0.01	488.1	126	79	61.46
500	0.2	589.43	127	78	61.95
500	0.4	568.1	127	78	61.95
500	0.6	598.33	127	78	61.95
500	0.9	458.29	165	40	80.49
1000	0.01	672.56	127	78	61.95
1000	0.2	702.31	127	78	61.95
1000	0.4	719.91	142	63	69.27
1000	0.6	746.07	175	30	85.37
1000	0.9	726.73	170	35	82.93
2000	0.01	1232.06	127	78	61.95
2000	0.2	1307.77	127	78	61.95
2000	0.4	979.24	171	34	83.41
2000	0.6	1061.52	177	28	86.34
2000	0.9	928.27	178	27	86.83
5000	0.01	1876.0	127	78	61.95
5000	0.2	1868.11	176	29	85.85
5000	0.4	2127.54	177	28	86.34
5000	0.6	1874.96	179	26	87.32
5000	0.9	1905.88	177	28	86.34
10000	0.01	3377.7	127	78	61.95
10000	0.2	3361.77	176	29	85.85
10000	0.4	3360.05	178	27	86.83
10000	0.6	3372.98	177	28	86.34
10000	0.9	3369.81	178	27	86.83
20000	0.01	7937.66	127	78	61.95
20000	0.2	6999.62	177	28	86.34
20000	0.4	6774.09	178	27	86.83
20000	0.6	6574.18	178	27	86.83
20000	0.9	6537.31	177	28	86.34
50000	0.01	19699.56	171	34	83.41
50000	0.2	17824.98	177	28	86.34
50000	0.4	18070.31	178	27	86.83
50000	0.6	18530.04	180	25	87.8
50000	0.9	19102.3	183	22	89.27
Czwarta iteracja					
10	0.01	564.94	78	127	38.05
10	0.2	444.38	127	78	61.95
10	0.4	458.43	127	78	61.95
10	0.6	433.7	127	78	61.95
10	0.9	419.06	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20	0.01	372.69	127	78	61.95
20	0.2	304.16	127	78	61.95
20	0.4	297.64	127	78	61.95
20	0.6	309.96	127	78	61.95
20	0.9	306.3	127	78	61.95
50	0.01	319.82	127	78	61.95
50	0.2	321.37	127	78	61.95
50	0.4	316.77	127	78	61.95
50	0.6	334.1	127	78	61.95
50	0.9	333.64	127	78	61.95
100	0.01	343.25	78	127	38.05
100	0.2	360.89	127	78	61.95
100	0.4	317.98	127	78	61.95
100	0.6	342.59	127	78	61.95
100	0.9	337.05	127	78	61.95
200	0.01	367.76	127	78	61.95
200	0.2	354.78	127	78	61.95
200	0.4	385.37	127	78	61.95
200	0.6	439.76	127	78	61.95
200	0.9	389.65	127	78	61.95
500	0.01	460.99	127	78	61.95
500	0.2	491.32	127	78	61.95
500	0.4	454.56	127	78	61.95
500	0.6	477.52	127	78	61.95
500	0.9	1504.9	153	52	74.63
1000	0.01	2135.83	127	78	61.95
1000	0.2	909.48	127	78	61.95
1000	0.4	780.11	154	51	75.12
1000	0.6	781.87	175	30	85.37
1000	0.9	712.83	174	31	84.88
2000	0.01	997.47	127	78	61.95
2000	0.2	1163.96	129	76	62.93
2000	0.4	1318.76	151	54	73.66
2000	0.6	1098.14	178	27	86.83
2000	0.9	1427.87	178	27	86.83
5000	0.01	2032.14	127	78	61.95
5000	0.2	2040.67	175	30	85.37
5000	0.4	1976.14	177	28	86.34
5000	0.6	1929.78	179	26	87.32
5000	0.9	2025.3	177	28	86.34
10000	0.01	3526.21	127	78	61.95
10000	0.2	3418.97	177	28	86.34
10000	0.4	3739.06	177	28	86.34
10000	0.6	3515.58	177	28	86.34

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10000	0.9	3581.59	177	28	86.34
20000	0.01	7784.68	127	78	61.95
20000	0.2	7121.45	178	27	86.83
20000	0.4	7556.17	177	28	86.34
20000	0.6	8064.46	177	28	86.34
20000	0.9	7592.09	177	28	86.34
50000	0.01	17490.91	145	60	70.73
50000	0.2	16044.4	176	29	85.85
50000	0.4	15956.22	179	26	87.32
50000	0.6	17312.71	180	25	87.8
50000	0.9	16306.12	179	26	87.32
Uśrednione wyniki					
10	0.01	583.53	90.00	115.00	43.90
10	0.2	335.23	114.75	90.25	55.98
10	0.4	340.02	127.00	78.00	61.95
10	0.6	333.08	127.00	78.00	61.95
10	0.9	326.86	127.00	78.00	61.95
20	0.01	311.63	102.50	102.50	50.00
20	0.2	297.46	110.50	94.50	53.90
20	0.4	675.33	127.00	78.00	61.95
20	0.6	301.10	127.00	78.00	61.95
20	0.9	684.43	127.00	78.00	61.95
50	0.01	308.18	114.75	90.25	55.98
50	0.2	311.62	127.00	78.00	61.95
50	0.4	310.63	127.00	78.00	61.95
50	0.6	311.02	127.00	78.00	61.95
50	0.9	313.18	127.00	78.00	61.95
100	0.01	329.93	100.50	104.50	49.03
100	0.2	334.36	127.00	78.00	61.95
100	0.4	322.26	127.00	78.00	61.95
100	0.6	329.97	127.00	78.00	61.95
100	0.9	330.87	127.00	78.00	61.95
200	0.01	358.39	127.00	78.00	61.95
200	0.2	739.88	127.00	78.00	61.95
200	0.4	367.37	127.00	78.00	61.95
200	0.6	377.25	127.00	78.00	61.95
200	0.9	371.96	127.00	78.00	61.95
500	0.01	459.55	126.75	78.25	61.83
500	0.2	495.06	127.00	78.00	61.95
500	0.4	477.91	127.00	78.00	61.95
500	0.6	494.30	127.00	78.00	61.95
500	0.9	713.91	150.75	54.25	73.54
1000	0.01	1002.65	127.00	78.00	61.95
1000	0.2	702.91	127.00	78.00	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
1000	0.4	673.03	153.50	51.50	74.88
1000	0.6	685.66	163.75	41.25	79.88
1000	0.9	663.48	173.25	31.75	84.52
2000	0.01	1011.63	127.00	78.00	61.95
2000	0.2	1068.25	137.50	67.50	67.07
2000	0.4	1036.47	167.25	37.75	81.58
2000	0.6	993.41	177.00	28.00	86.34
2000	0.9	1041.15	177.50	27.50	86.59
5000	0.01	2132.79	127.00	78.00	61.95
5000	0.2	1895.92	174.00	31.00	84.88
5000	0.4	1956.77	177.50	27.50	86.59
5000	0.6	1869.77	178.75	26.25	87.20
5000	0.9	2177.70	177.00	28.00	86.34
10000	0.01	3585.60	127.00	78.00	61.95
10000	0.2	3581.00	177.00	28.00	86.34
10000	0.4	3754.06	177.25	27.75	86.46
10000	0.6	3505.16	177.00	28.00	86.34
10000	0.9	3640.80	177.50	27.50	86.59
20000	0.01	7173.72	127.00	78.00	61.95
20000	0.2	6791.94	177.50	27.50	86.59
20000	0.4	6880.66	177.25	27.75	86.46
20000	0.6	6921.98	177.75	27.25	86.71
20000	0.9	6802.40	177.25	27.75	86.46
50000	0.01	17222.58	155.25	49.75	75.73
50000	0.2	16427.04	176.50	28.50	86.10
50000	0.4	16439.11	178.75	26.25	87.20
50000	0.6	16852.32	180.00	25.00	87.80
50000	0.9	16797.03	181.75	23.25	88.66

Tabela 5.1: Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem wstecznej propagacji błędów.

Sieć składająca się z trzech warstw ukrytych

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja					
10	0.01	552.77	78	127	38.05
10	0.2	559.75	127	78	61.95
10	0.4	557.01	127	78	61.95
10	0.6	553.9	78	127	38.05
10	0.9	548.67	127	78	61.95
20	0.01	564.89	127	78	61.95
20	0.2	561.11	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20	0.4	556.8	127	78	61.95
20	0.6	555.84	127	78	61.95
20	0.9	552.57	127	78	61.95
50	0.01	556.13	78	127	38.05
50	0.2	554.89	127	78	61.95
50	0.4	553.32	127	78	61.95
50	0.6	553.71	127	78	61.95
50	0.9	2239.84	127	78	61.95
100	0.01	584.37	78	127	38.05
100	0.2	583.92	127	78	61.95
100	0.4	582.14	127	78	61.95
100	0.6	588.38	127	78	61.95
100	0.9	586.61	127	78	61.95
200	0.01	634.98	127	78	61.95
200	0.2	634.59	127	78	61.95
200	0.4	636.04	127	78	61.95
200	0.6	638.66	127	78	61.95
200	0.9	633.23	127	78	61.95
500	0.01	777.0	127	78	61.95
500	0.2	773.61	127	78	61.95
500	0.4	775.72	127	78	61.95
500	0.6	781.76	127	78	61.95
500	0.9	775.8	127	78	61.95
1000	0.01	1041.44	127	78	61.95
1000	0.2	1075.54	127	78	61.95
1000	0.4	1005.61	127	78	61.95
1000	0.6	1000.47	127	78	61.95
1000	0.9	2020.55	127	78	61.95
2000	0.01	1472.81	127	78	61.95
2000	0.2	2494.86	127	78	61.95
2000	0.4	1493.89	127	78	61.95
2000	0.6	1492.58	127	78	61.95
2000	0.9	1538.45	127	78	61.95
5000	0.01	2918.96	127	78	61.95
5000	0.2	2951.17	127	78	61.95
5000	0.4	2893.9	180	25	87.8
5000	0.6	2946.65	127	78	61.95
5000	0.9	2937.58	163	42	79.51
10000	0.01	7436.03	127	78	61.95
10000	0.2	5689.98	127	78	61.95
10000	0.4	6236.52	177	28	86.34
10000	0.6	6161.35	177	28	86.34
10000	0.9	6272.65	177	28	86.34
20000	0.01	10189.13	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20000	0.2	10126.78	127	78	61.95
20000	0.4	10022.08	177	28	86.34
20000	0.6	10002.05	178	27	86.83
20000	0.9	9970.07	179	26	87.32
50000	0.01	24264.42	127	78	61.95
50000	0.2	24293.1	177	28	86.34
50000	0.4	24093.68	178	27	86.83
50000	0.6	23967.13	177	28	86.34
50000	0.9	24093.07	177	28	86.34
Druga iteracja					
10	0.01	539.61	78	127	38.05
10	0.2	551.99	127	78	61.95
10	0.4	546.26	78	127	38.05
10	0.6	533.77	127	78	61.95
10	0.9	541.08	127	78	61.95
20	0.01	545.49	127	78	61.95
20	0.2	556.72	127	78	61.95
20	0.4	550.75	127	78	61.95
20	0.6	543.19	127	78	61.95
20	0.9	551.67	127	78	61.95
50	0.01	556.85	127	78	61.95
50	0.2	542.79	127	78	61.95
50	0.4	548.67	127	78	61.95
50	0.6	2226.07	127	78	61.95
50	0.9	564.63	127	78	61.95
100	0.01	573.69	127	78	61.95
100	0.2	586.5	127	78	61.95
100	0.4	584.56	127	78	61.95
100	0.6	572.68	127	78	61.95
100	0.9	583.0	127	78	61.95
200	0.01	621.83	78	127	38.05
200	0.2	636.99	127	78	61.95
200	0.4	633.11	127	78	61.95
200	0.6	621.53	127	78	61.95
200	0.9	625.84	127	78	61.95
500	0.01	764.6	127	78	61.95
500	0.2	765.45	127	78	61.95
500	0.4	756.41	127	78	61.95
500	0.6	767.77	127	78	61.95
500	0.9	761.28	127	78	61.95
1000	0.01	994.89	127	78	61.95
1000	0.2	999.94	127	78	61.95
1000	0.4	1935.44	127	78	61.95
1000	0.6	1014.1	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
1000	0.9	1002.95	127	78	61.95
2000	0.01	2439.09	127	78	61.95
2000	0.2	1471.93	127	78	61.95
2000	0.4	1615.45	127	78	61.95
2000	0.6	1472.76	127	78	61.95
2000	0.9	1482.53	177	28	86.34
5000	0.01	2867.86	127	78	61.95
5000	0.2	2871.66	127	78	61.95
5000	0.4	2881.71	127	78	61.95
5000	0.6	2877.99	127	78	61.95
5000	0.9	2863.06	174	31	84.88
10000	0.01	5217.62	127	78	61.95
10000	0.2	5195.56	127	78	61.95
10000	0.4	5179.65	175	30	85.37
10000	0.6	5199.56	176	29	85.85
10000	0.9	5180.87	177	28	86.34
20000	0.01	9868.01	127	78	61.95
20000	0.2	9876.54	176	29	85.85
20000	0.4	9862.45	177	28	86.34
20000	0.6	9810.79	178	27	86.83
20000	0.9	9837.45	177	28	86.34
50000	0.01	23894.3	127	78	61.95
50000	0.2	30186.45	177	28	86.34
50000	0.4	35438.78	180	25	87.8
50000	0.6	30175.33	179	26	87.32
50000	0.9	33490.39	179	26	87.32
Trzecia iteracja					
10	0.01	537.31	78	127	38.05
10	0.2	540.86	78	127	38.05
10	0.4	537.98	127	78	61.95
10	0.6	2004.96	127	78	61.95
10	0.9	564.46	127	78	61.95
20	0.01	540.42	127	78	61.95
20	0.2	536.89	127	78	61.95
20	0.4	539.46	127	78	61.95
20	0.6	542.22	127	78	61.95
20	0.9	537.54	127	78	61.95
50	0.01	575.93	127	78	61.95
50	0.2	564.87	127	78	61.95
50	0.4	561.99	127	78	61.95
50	0.6	561.87	127	78	61.95
50	0.9	568.42	127	78	61.95
100	0.01	594.59	78	127	38.05
100	0.2	592.32	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
100	0.4	588.13	127	78	61.95
100	0.6	584.89	127	78	61.95
100	0.9	593.07	127	78	61.95
200	0.01	656.65	78	127	38.05
200	0.2	650.55	127	78	61.95
200	0.4	665.68	127	78	61.95
200	0.6	635.42	127	78	61.95
200	0.9	652.37	127	78	61.95
500	0.01	805.96	127	78	61.95
500	0.2	928.7	127	78	61.95
500	0.4	798.16	127	78	61.95
500	0.6	985.98	127	78	61.95
500	0.9	1074.37	127	78	61.95
1000	0.01	1056.32	127	78	61.95
1000	0.2	1047.45	127	78	61.95
1000	0.4	1016.22	127	78	61.95
1000	0.6	1008.73	127	78	61.95
1000	0.9	1004.27	127	78	61.95
2000	0.01	1566.4	127	78	61.95
2000	0.2	1516.1	127	78	61.95
2000	0.4	1667.37	127	78	61.95
2000	0.6	1597.36	127	78	61.95
2000	0.9	1531.45	127	78	61.95
5000	0.01	3146.73	127	78	61.95
5000	0.2	2978.47	127	78	61.95
5000	0.4	3867.16	127	78	61.95
5000	0.6	2905.16	127	78	61.95
5000	0.9	2891.69	176	29	85.85
10000	0.01	6276.59	127	78	61.95
10000	0.2	5243.07	127	78	61.95
10000	0.4	5241.41	127	78	61.95
10000	0.6	5246.7	176	29	85.85
10000	0.9	5253.95	177	28	86.34
20000	0.01	10226.34	127	78	61.95
20000	0.2	11422.91	127	78	61.95
20000	0.4	10855.81	177	28	86.34
20000	0.6	11577.71	177	28	86.34
20000	0.9	11272.94	179	26	87.32
50000	0.01	25134.37	127	78	61.95
50000	0.2	29859.15	178	27	86.83
50000	0.4	24332.46	180	25	87.8
50000	0.6	24063.82	179	26	87.32
50000	0.9	24217.19	179	26	87.32
Czwarta iteracja					

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10	0.01	794.33	127	78	61.95
10	0.2	797.05	78	127	38.05
10	0.4	605.86	127	78	61.95
10	0.6	617.01	127	78	61.95
10	0.9	687.41	127	78	61.95
20	0.01	568.32	78	127	38.05
20	0.2	564.44	78	127	38.05
20	0.4	588.29	127	78	61.95
20	0.6	573.37	127	78	61.95
20	0.9	561.35	127	78	61.95
50	0.01	577.82	127	78	61.95
50	0.2	581.16	127	78	61.95
50	0.4	599.89	127	78	61.95
50	0.6	628.32	127	78	61.95
50	0.9	599.19	127	78	61.95
100	0.01	600.51	78	127	38.05
100	0.2	2417.44	127	78	61.95
100	0.4	625.01	127	78	61.95
100	0.6	627.85	127	78	61.95
100	0.9	637.88	127	78	61.95
200	0.01	661.28	127	78	61.95
200	0.2	669.74	127	78	61.95
200	0.4	2084.38	127	78	61.95
200	0.6	654.02	127	78	61.95
200	0.9	671.61	127	78	61.95
500	0.01	833.12	78	127	38.05
500	0.2	803.68	127	78	61.95
500	0.4	779.99	127	78	61.95
500	0.6	836.16	127	78	61.95
500	0.9	799.3	127	78	61.95
1000	0.01	1071.35	127	78	61.95
1000	0.2	1193.21	127	78	61.95
1000	0.4	1080.97	127	78	61.95
1000	0.6	1118.91	127	78	61.95
1000	0.9	1046.93	127	78	61.95
2000	0.01	1920.38	127	78	61.95
2000	0.2	1765.83	127	78	61.95
2000	0.4	1566.87	127	78	61.95
2000	0.6	1724.67	127	78	61.95
2000	0.9	1680.85	179	26	87.32
5000	0.01	3276.95	127	78	61.95
5000	0.2	3101.93	127	78	61.95
5000	0.4	3065.7	127	78	61.95
5000	0.6	3064.69	177	28	86.34

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
5000	0.9	3733.34	176	29	85.85
10000	0.01	7383.1	127	78	61.95
10000	0.2	6774.82	127	78	61.95
10000	0.4	5503.79	127	78	61.95
10000	0.6	5523.48	177	28	86.34
10000	0.9	6758.43	177	28	86.34
20000	0.01	11532.6	127	78	61.95
20000	0.2	11318.54	179	26	87.32
20000	0.4	10657.95	176	29	85.85
20000	0.6	13247.2	177	28	86.34
20000	0.9	12056.94	179	26	87.32
50000	0.01	24732.29	127	78	61.95
50000	0.2	24475.6	176	29	85.85
50000	0.4	24559.67	180	25	87.8
50000	0.6	24682.68	179	26	87.32
50000	0.9	24527.01	177	28	86.34
Uśrednione wyniki					
10	0.01	606.01	90.25	114.75	44.03
10	0.2	612.41	102.5	102.5	50
10	0.4	561.78	114.75	90.25	55.98
10	0.6	927.41	114.75	90.25	55.98
10	0.9	585.41	127	78	61.95
20	0.01	554.78	114.75	90.25	55.98
20	0.2	554.79	114.75	90.25	55.98
20	0.4	558.83	127	78	61.95
20	0.6	553.66	127	78	61.95
20	0.9	550.78	127	78	61.95
50	0.01	566.68	114.75	90.25	55.98
50	0.2	560.93	127	78	61.95
50	0.4	565.97	127	78	61.95
50	0.6	992.49	127	78	61.95
50	0.9	993.02	127	78	61.95
100	0.01	588.29	90.25	114.75	44.03
100	0.2	1045.05	127	78	61.95
100	0.4	594.96	127	78	61.95
100	0.6	593.45	127	78	61.95
100	0.9	600.14	127	78	61.95
200	0.01	643.69	102.5	102.5	50
200	0.2	647.97	127	78	61.95
200	0.4	1004.8	127	78	61.95
200	0.6	637.41	127	78	61.95
200	0.9	645.76	127	78	61.95
500	0.01	795.17	114.75	90.25	55.98
500	0.2	817.86	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
500	0.4	777.57	127	78	61.95
500	0.6	842.92	127	78	61.95
500	0.9	852.69	127	78	61.95
1000	0.01	1041	127	78	61.95
1000	0.2	1079.04	127	78	61.95
1000	0.4	1259.56	127	78	61.95
1000	0.6	1035.55	127	78	61.95
1000	0.9	1268.68	127	78	61.95
2000	0.01	1849.67	127	78	61.95
2000	0.2	1812.18	127	78	61.95
2000	0.4	1585.9	127	78	61.95
2000	0.6	1571.84	127	78	61.95
2000	0.9	1558.32	152.5	52.5	74.39
5000	0.01	3052.63	127	78	61.95
5000	0.2	2975.81	127	78	61.95
5000	0.4	3177.12	140.25	64.75	68.41
5000	0.6	2948.62	139.5	65.5	68.05
5000	0.9	3106.42	172.25	32.75	84.02
10000	0.01	6578.34	127	78	61.95
10000	0.2	5725.86	127	78	61.95
10000	0.4	5540.34	151.5	53.5	73.9
10000	0.6	5532.77	176.5	28.5	86.1
10000	0.9	5866.48	177	28	86.34
20000	0.01	10454.02	127	78	61.95
20000	0.2	10686.19	152.25	52.75	74.27
20000	0.4	10349.57	176.75	28.25	86.22
20000	0.6	11159.44	177.5	27.5	86.59
20000	0.9	10784.35	178.5	26.5	87.08
50000	0.01	24506.35	127	78	61.95
50000	0.2	27203.58	177	28	86.34
50000	0.4	27106.15	179.5	25.5	87.56
50000	0.6	25722.24	178.5	26.5	87.08
50000	0.9	26581.92	178	27	86.83

Tabela 5.2: Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem wstecznej propagacji błędów.

Sieć składająca się z pięciu warstw ukrytych

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja					
10	0.01	853.16	127	78	61.95
10	0.2	845.0	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10	0.4	845.65	127	78	61.95
10	0.6	838.26	127	78	61.95
10	0.9	834.14	127	78	61.95
20	0.01	869.01	127	78	61.95
20	0.2	858.86	127	78	61.95
20	0.4	857.8	127	78	61.95
20	0.6	849.72	127	78	61.95
20	0.9	855.28	127	78	61.95
50	0.01	900.66	127	78	61.95
50	0.2	889.38	127	78	61.95
50	0.4	889.95	127	78	61.95
50	0.6	875.51	127	78	61.95
50	0.9	874.65	127	78	61.95
100	0.01	891.72	127	78	61.95
100	0.2	2607.89	127	78	61.95
100	0.4	922.11	127	78	61.95
100	0.6	928.67	127	78	61.95
100	0.9	918.72	127	78	61.95
200	0.01	969.87	78	127	38.05
200	0.2	959.22	127	78	61.95
200	0.4	2398.3	127	78	61.95
200	0.6	983.41	127	78	61.95
200	0.9	973.72	127	78	61.95
500	0.01	1218.2	127	78	61.95
500	0.2	3286.9	127	78	61.95
500	0.4	1866.28	127	78	61.95
500	0.6	1772.5	127	78	61.95
500	0.9	1277.1	127	78	61.95
1000	0.01	1947.56	127	78	61.95
1000	0.2	1470.47	127	78	61.95
1000	0.4	1461.3	127	78	61.95
1000	0.6	1505.96	127	78	61.95
1000	0.9	1459.88	127	78	61.95
2000	0.01	2090.5	127	78	61.95
2000	0.2	2075.47	127	78	61.95
2000	0.4	2138.62	127	78	61.95
2000	0.6	2069.88	127	78	61.95
2000	0.9	2153.82	127	78	61.95
5000	0.01	3956.83	127	78	61.95
5000	0.2	3987.54	127	78	61.95
5000	0.4	3987.99	127	78	61.95
5000	0.6	4459.73	127	78	61.95
5000	0.9	5965.53	127	78	61.95
10000	0.01	7195.01	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10000	0.2	7252.29	127	78	61.95
10000	0.4	7446.04	127	78	61.95
10000	0.6	8064.5	127	78	61.95
10000	0.9	7225.91	127	78	61.95
20000	0.01	13365.27	127	78	61.95
20000	0.2	13249.12	127	78	61.95
20000	0.4	14372.34	127	78	61.95
20000	0.6	13438.34	127	78	61.95
20000	0.9	13370.98	127	78	61.95
50000	0.01	31693.91	127	78	61.95
50000	0.2	33643.57	127	78	61.95
50000	0.4	32152.62	170	35	82.93
50000	0.6	32065.6	127	78	61.95
50000	0.9	32042.7	127	78	61.95
Druga iteracja					
10	0.01	836.12	127	78	61.95
10	0.2	840.91	127	78	61.95
10	0.4	836.2	127	78	61.95
10	0.6	838.75	127	78	61.95
10	0.9	838.61	127	78	61.95
20	0.01	842.81	78	127	38.05
20	0.2	845.72	127	78	61.95
20	0.4	848.71	127	78	61.95
20	0.6	860.28	127	78	61.95
20	0.9	850.63	127	78	61.95
50	0.01	877.42	78	127	38.05
50	0.2	876.93	127	78	61.95
50	0.4	860.05	127	78	61.95
50	0.6	872.86	127	78	61.95
50	0.9	868.25	127	78	61.95
100	0.01	898.89	78	127	38.05
100	0.2	2572.77	127	78	61.95
100	0.4	906.19	127	78	61.95
100	0.6	905.98	127	78	61.95
100	0.9	901.55	127	78	61.95
200	0.01	956.03	127	78	61.95
200	0.2	2322.89	127	78	61.95
200	0.4	964.71	127	78	61.95
200	0.6	959.35	127	78	61.95
200	0.9	952.57	127	78	61.95
500	0.01	2115.16	127	78	61.95
500	0.2	1143.08	127	78	61.95
500	0.4	1138.35	127	78	61.95
500	0.6	1145.25	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
500	0.9	1131.8	127	78	61.95
1000	0.01	1447.16	127	78	61.95
1000	0.2	1447.95	127	78	61.95
1000	0.4	1439.56	127	78	61.95
1000	0.6	1443.35	127	78	61.95
1000	0.9	1445.34	127	78	61.95
2000	0.01	2059.67	127	78	61.95
2000	0.2	2051.45	127	78	61.95
2000	0.4	2048.16	127	78	61.95
2000	0.6	2045.98	127	78	61.95
2000	0.9	2053.1	127	78	61.95
5000	0.01	3893.67	127	78	61.95
5000	0.2	3905.07	127	78	61.95
5000	0.4	3895.29	127	78	61.95
5000	0.6	4906.58	127	78	61.95
5000	0.9	3923.25	127	78	61.95
10000	0.01	6947.64	127	78	61.95
10000	0.2	6954.0	127	78	61.95
10000	0.4	7981.55	127	78	61.95
10000	0.6	7012.73	127	78	61.95
10000	0.9	7009.51	127	78	61.95
20000	0.01	13047.47	127	78	61.95
20000	0.2	14207.67	127	78	61.95
20000	0.4	13157.13	127	78	61.95
20000	0.6	13169.65	127	78	61.95
20000	0.9	13173.64	127	78	61.95
50000	0.01	35796.37	127	78	61.95
50000	0.2	35086.29	127	78	61.95
50000	0.4	35652.01	127	78	61.95
50000	0.6	35697.0	127	78	61.95
50000	0.9	35677.41	127	78	61.95
Trzecia iteracja					
10	0.01	859.31	78	127	38.05
10	0.2	863.29	127	78	61.95
10	0.4	850.01	78	127	38.05
10	0.6	851.07	127	78	61.95
10	0.9	838.09	127	78	61.95
20	0.01	835.19	78	127	38.05
20	0.2	830.84	127	78	61.95
20	0.4	2586.18	127	78	61.95
20	0.6	988.63	127	78	61.95
20	0.9	928.0	127	78	61.95
50	0.01	863.94	127	78	61.95
50	0.2	856.44	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50	0.4	883.27	127	78	61.95
50	0.6	885.24	127	78	61.95
50	0.9	2597.94	127	78	61.95
100	0.01	900.24	127	78	61.95
100	0.2	908.26	127	78	61.95
100	0.4	907.63	127	78	61.95
100	0.6	890.25	127	78	61.95
100	0.9	891.88	127	78	61.95
200	0.01	1324.71	127	78	61.95
200	0.2	1135.95	127	78	61.95
200	0.4	1014.14	127	78	61.95
200	0.6	1039.99	127	78	61.95
200	0.9	2413.6	127	78	61.95
500	0.01	1368.3	127	78	61.95
500	0.2	1224.24	127	78	61.95
500	0.4	1352.54	127	78	61.95
500	0.6	2231.51	127	78	61.95
500	0.9	1201.01	127	78	61.95
1000	0.01	1491.12	127	78	61.95
1000	0.2	2829.38	127	78	61.95
1000	0.4	1649.27	127	78	61.95
1000	0.6	1827.55	127	78	61.95
1000	0.9	1509.27	127	78	61.95
2000	0.01	3378.87	127	78	61.95
2000	0.2	2185.72	127	78	61.95
2000	0.4	2135.34	127	78	61.95
2000	0.6	2107.77	127	78	61.95
2000	0.9	2074.35	127	78	61.95
5000	0.01	4075.23	127	78	61.95
5000	0.2	3948.61	127	78	61.95
5000	0.4	4079.06	127	78	61.95
5000	0.6	3920.74	127	78	61.95
5000	0.9	3936.71	127	78	61.95
10000	0.01	7038.28	127	78	61.95
10000	0.2	7051.23	127	78	61.95
10000	0.4	7020.14	127	78	61.95
10000	0.6	7597.74	127	78	61.95
10000	0.9	7320.78	127	78	61.95
20000	0.01	14688.16	127	78	61.95
20000	0.2	14561.92	127	78	61.95
20000	0.4	13579.89	127	78	61.95
20000	0.6	15401.55	127	78	61.95
20000	0.9	15749.46	127	78	61.95
50000	0.01	33734.98	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50000	0.2	36774.33	127	78	61.95
50000	0.4	37081.51	127	78	61.95
50000	0.6	34546.77	176	29	85.85
50000	0.9	33509.9	175	30	85.37
Czwarta iteracja					
10	0.01	1118.0	78	127	38.05
10	0.2	2761.35	78	127	38.05
10	0.4	889.01	127	78	61.95
10	0.6	848.55	127	78	61.95
10	0.9	874.87	127	78	61.95
20	0.01	906.51	127	78	61.95
20	0.2	858.02	127	78	61.95
20	0.4	910.45	127	78	61.95
20	0.6	872.74	127	78	61.95
20	0.9	2655.05	127	78	61.95
50	0.01	984.44	127	78	61.95
50	0.2	898.7	127	78	61.95
50	0.4	949.96	127	78	61.95
50	0.6	924.45	127	78	61.95
50	0.9	923.89	127	78	61.95
100	0.01	950.59	127	78	61.95
100	0.2	935.81	127	78	61.95
100	0.4	959.14	127	78	61.95
100	0.6	932.24	127	78	61.95
100	0.9	938.66	127	78	61.95
200	0.01	1062.05	127	78	61.95
200	0.2	1010.76	127	78	61.95
200	0.4	1055.6	127	78	61.95
200	0.6	1139.32	127	78	61.95
200	0.9	1018.7	127	78	61.95
500	0.01	1196.28	78	127	38.05
500	0.2	1152.88	127	78	61.95
500	0.4	1154.56	127	78	61.95
500	0.6	1235.31	127	78	61.95
500	0.9	1326.18	127	78	61.95
1000	0.01	1512.77	127	78	61.95
1000	0.2	1510.58	127	78	61.95
1000	0.4	1591.95	127	78	61.95
1000	0.6	2634.2	127	78	61.95
1000	0.9	1605.89	127	78	61.95
2000	0.01	2214.17	127	78	61.95
2000	0.2	2052.84	127	78	61.95
2000	0.4	3139.37	127	78	61.95
2000	0.6	2261.0	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
2000	0.9	2181.83	127	78	61.95
5000	0.01	5243.84	127	78	61.95
5000	0.2	6102.98	127	78	61.95
5000	0.4	4582.98	127	78	61.95
5000	0.6	4692.74	127	78	61.95
5000	0.9	4365.3	127	78	61.95
10000	0.01	7785.43	127	78	61.95
10000	0.2	7358.17	127	78	61.95
10000	0.4	8707.41	127	78	61.95
10000	0.6	8720.83	127	78	61.95
10000	0.9	7792.42	127	78	61.95
20000	0.01	16902.52	127	78	61.95
20000	0.2	15476.25	127	78	61.95
20000	0.4	15638.82	127	78	61.95
20000	0.6	15704.5	127	78	61.95
20000	0.9	15550.43	176	29	85.85
50000	0.01	32408.2	127	78	61.95
50000	0.2	32316.26	127	78	61.95
50000	0.4	32458.82	127	78	61.95
50000	0.6	31968.73	127	78	61.95
50000	0.9	33791.24	175	30	85.37
Uśrednione wyniki					
10	0.01	916.65	102.50	102.50	50.00
10	0.2	1327.64	114.75	90.25	55.98
10	0.4	855.22	114.75	90.25	55.98
10	0.6	844.16	127.00	78.00	61.95
10	0.9	846.43	127.00	78.00	61.95
20	0.01	863.38	102.50	102.50	50.00
20	0.2	848.36	127.00	78.00	61.95
20	0.4	1300.79	127.00	78.00	61.95
20	0.6	892.84	127.00	78.00	61.95
20	0.9	1322.24	127.00	78.00	61.95
50	0.01	906.62	114.75	90.25	55.98
50	0.2	880.36	127.00	78.00	61.95
50	0.4	895.81	127.00	78.00	61.95
50	0.6	889.52	127.00	78.00	61.95
50	0.9	1316.18	127.00	78.00	61.95
100	0.01	910.36	114.75	90.25	55.98
100	0.2	1756.18	127.00	78.00	61.95
100	0.4	923.77	127.00	78.00	61.95
100	0.6	914.29	127.00	78.00	61.95
100	0.9	912.70	127.00	78.00	61.95
200	0.01	1078.17	114.75	90.25	55.98
200	0.2	1357.21	127.00	78.00	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
200	0.4	1358.19	127.00	78.00	61.95
200	0.6	1030.52	127.00	78.00	61.95
200	0.9	1339.65	127.00	78.00	61.95
500	0.01	1474.49	114.75	90.25	55.98
500	0.2	1701.78	127.00	78.00	61.95
500	0.4	1377.93	127.00	78.00	61.95
500	0.6	1596.14	127.00	78.00	61.95
500	0.9	1234.02	127.00	78.00	61.95
1000	0.01	1599.65	127.00	78.00	61.95
1000	0.2	1814.60	127.00	78.00	61.95
1000	0.4	1535.52	127.00	78.00	61.95
1000	0.6	1852.77	127.00	78.00	61.95
1000	0.9	1505.10	127.00	78.00	61.95
2000	0.01	2435.80	127.00	78.00	61.95
2000	0.2	2091.37	127.00	78.00	61.95
2000	0.4	2365.37	127.00	78.00	61.95
2000	0.6	2121.16	127.00	78.00	61.95
2000	0.9	2115.78	127.00	78.00	61.95
5000	0.01	4292.39	127.00	78.00	61.95
5000	0.2	4486.05	127.00	78.00	61.95
5000	0.4	4136.33	127.00	78.00	61.95
5000	0.6	4494.95	127.00	78.00	61.95
5000	0.9	4547.70	127.00	78.00	61.95
10000	0.01	7241.59	127.00	78.00	61.95
10000	0.2	7153.92	127.00	78.00	61.95
10000	0.4	7788.79	127.00	78.00	61.95
10000	0.6	7848.95	127.00	78.00	61.95
10000	0.9	7337.16	127.00	78.00	61.95
20000	0.01	14500.86	127.00	78.00	61.95
20000	0.2	14373.74	127.00	78.00	61.95
20000	0.4	14187.05	127.00	78.00	61.95
20000	0.6	14428.51	127.00	78.00	61.95
20000	0.9	14461.13	139.25	65.75	67.93
50000	0.01	33408.37	127.00	78.00	61.95
50000	0.2	34455.11	127.00	78.00	61.95
50000	0.4	34336.24	137.75	67.25	67.20
50000	0.6	33569.53	139.25	65.75	67.93
50000	0.9	33755.31	151.00	54.00	73.66

Tabela 5.3: Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem wstecznej propagacji błędów.

5.2 Algorytm zmiennej metryki

W części tej zobrazowano wyniki badań dla algorytmu zmiennej metryki (Quasi-Newtona). W metodzie tej parametrem, jaki był zmieniany w celu określenia najlepszej jakości uczenia była liczba epok.

Sieć składająca się z jednej warstwy ukrytej

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja				
10	16625.58	127	78	61.95
20	14898.79	173	32	84.39
30	15741.75	174	31	84.88
50	16188.64	176	29	85.85
100	23044.81	181	24	88.29
150	16760.69	175	30	85.37
200	15153.4	178	27	86.83
250	17622.47	181	24	88.29
300	17016.93	175	30	85.37
350	18146.47	176	29	85.85
400	17742.08	176	29	85.85
450	17988.93	178	27	86.83
500	20111.83	179	26	87.32
Druga iteracja				
10	14603.39	127	78	61.95
20	16046.22	175	30	85.37
30	14565.92	177	28	86.34
50	14792.4	177	28	86.34
100	14787.53	180	25	87.8
150	16611.05	179	26	87.32
200	17061.33	179	26	87.32
250	15088.37	173	32	84.39
300	17231.14	127	78	61.95
350	16674.2	86	119	41.95
400	16741.35	180	25	87.8
450	17547.23	182	23	88.78
500	15651.23	138	67	67.32
Trzecia iteracja				
10	15513.33	175	30	85.37
20	16008.4	173	32	84.39
30	15941.07	176	29	85.85
50	15354.3	175	30	85.37
100	16746.93	176	29	85.85
150	17940.2	178	27	86.83
200	17212.44	139	66	67.8

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
250	16993.84	176	29	85.85
300	18000.98	170	35	82.93
350	17560.52	127	78	61.95
400	21020.28	180	25	87.8
450	18439.29	127	78	61.95
500	19879.15	175	30	85.37
Czwarta iteracja				
10	15507.19	127	78	61.95
20	17178.04	172	33	83.9
30	16773.68	175	30	85.37
50	18076.12	175	30	85.37
100	16388.2	180	25	87.8
150	17118.9	178	27	86.83
200	19497.23	173	32	84.39
250	15550.01	177	28	86.34
300	16148.62	180	25	87.8
350	18279.28	175	30	85.37
400	17984.29	173	32	84.39
450	18740.98	170	35	82.93
500	20897.57	177	28	86.34
Uśrednione wyniki				
10	15562.37	139.00	66.00	67.81
20	16032.86	173.25	31.75	84.51
30	15755.61	175.50	29.50	85.61
50	16102.87	175.75	29.25	85.73
100	17741.87	179.25	25.75	87.44
150	17107.71	177.50	27.50	86.59
200	17231.10	167.25	37.75	81.59
250	16313.67	176.75	28.25	86.22
300	17099.42	163.00	42.00	79.51
350	17665.12	141.00	64.00	68.78
400	18372.00	177.25	27.75	86.46
450	18179.11	164.25	40.75	80.12
500	19134.95	167.25	37.75	81.59

Tabela 5.4: Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem zmiennej metryki.

Sieć składająca się z trzech warstw ukrytych

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja				
10	25413.5	127	78	61.95

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20	26220.03	127	78	61.95
30	26398.56	172	33	83.9
50	27225.11	172	33	83.9
100	29476.52	178	27	86.83
150	28963.32	177	28	86.34
200	29559.22	177	28	86.34
250	29087.51	174	31	84.88
300	29523.32	175	30	85.37
350	32533.8	177	28	86.34
400	34618.73	127	78	61.95
450	33805.39	171	34	83.41
500	31596.76	172	33	83.9
Druga iteracja				
10	25707.77	127	78	61.95
20	25538.67	127	78	61.95
30	27698.54	127	78	61.95
50	27777.47	172	33	83.9
100	27951.49	181	24	88.29
150	26575.38	176	29	85.85
200	29224.56	177	28	86.34
250	28345.26	175	30	85.37
300	26822.34	170	35	82.93
350	28277.11	174	31	84.88
400	26859.63	183	22	89.27
450	26787.55	172	33	83.9
500	31226.45	175	30	85.37
Trzecia iteracja				
10	25993.25	127	78	61.95
20	25628.82	127	78	61.95
30	26905.29	127	78	61.95
50	29161.85	178	27	86.83
100	29845.91	174	31	84.88
150	35816.98	78	127	38.05
200	31143.16	179	26	87.32
250	33376.6	174	31	84.88
300	33478.26	175	30	85.37
350	33925.33	45	160	21.95
400	38332.21	178	27	86.83
450	31213.89	178	27	86.83
500	40803.2	175	30	85.37
Czwarta iteracja				
10	27234.91	127	78	61.95
20	27949.5	133	72	64.88
30	28824.66	176	29	85.85

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50	28931.57	175	30	85.37
100	29994.96	177	28	86.34
150	31953.74	175	30	85.37
200	29506.23	172	33	83.9
250	28601.47	175	30	85.37
300	30631.21	179	26	87.32
350	27519.36	177	28	86.34
400	29877.75	175	30	85.37
450	31005.56	174	31	84.88
500	33853.52	175	30	85.37
Uśrednione wyniki				
10	26087.36	127	78	61.95
20	26334.26	128.5	76.5	62.68
30	27456.76	150.5	54.5	73.41
50	28274	174.25	30.75	85
100	29317.22	177.5	27.5	86.59
150	30827.36	151.5	53.5	73.9
200	29858.29	176.25	28.75	85.98
250	29852.71	174.5	30.5	85.13
300	30113.78	174.75	30.25	85.25
350	30563.9	143.25	61.75	69.88
400	32422.08	165.75	39.25	80.86
450	30703.1	173.75	31.25	84.76
500	34369.98	174.25	30.75	85

Tabela 5.5: Wyniki badań dla sieci neuronowej składającej się z 3 warstw ukrytych, uczonej algorytmem zmiennej metryki.

Sieć składająca się z pięciu warstw ukrytych

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja				
10	37589.59	127	78	61.95
20	37639.86	127	78	61.95
30	38337.27	127	78	61.95
50	40343.8	127	78	61.95
100	41011.84	172	33	83.9
150	44428.4	180	25	87.8
200	45235.98	176	29	85.85
250	58815.38	174	31	84.88
300	45858.95	145	60	70.73
350	52887.38	181	24	88.29
400	64946.18	181	24	88.29

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
450	58938.18	175	30	85.37
500	62195.4	169	36	82.44
Drua iteracja				
10	38148.87	127	78	61.95
20	40147.03	127	78	61.95
30	39657.6	179	26	87.32
50	40223.09	168	37	81.95
100	41655.67	180	25	87.8
150	43913.08	170	35	82.93
200	43800.66	173	32	84.39
250	46707.73	177	28	86.34
300	47900.05	178	27	86.83
350	49718.55	178	27	86.83
400	114197.74	174	31	84.88
450	46436.62	170	35	82.93
500	53324.05	174	31	84.88
Trzecia iteracja				
10	39838.0	127	78	61.95
20	39534.19	127	78	61.95
30	40337.54	127	78	61.95
50	47690.04	174	31	84.88
100	49470.48	144	61	70.24
150	50282.31	171	34	83.41
200	49744.64	178	27	86.83
250	56744.97	176	29	85.85
300	51532.34	181	24	88.29
350	53979.88	172	33	83.9
400	64421.15	180	25	87.8
450	66387.63	176	29	85.85
500	54341.36	78	127	38.05
Czwarta iteracja				
10	40495.16	127	78	61.95
20	41289.84	127	78	61.95
30	41667.96	127	78	61.95
50	42354.56	171	34	83.41
100	51881.91	127	78	61.95
150	46306.53	174	31	84.88
200	48626.39	175	30	85.37
250	56070.26	178	27	86.83
300	49966.06	178	27	86.83
350	47347.48	127	78	61.95
400	53972.64	175	30	85.37
450	53701.23	176	29	85.85
500	66549.04	177	28	86.34

Liczba epok	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Uśrednione wyniki				
10	39017.91	127	78	61.95
20	39652.73	127	78	61.95
30	40000.09	140	65	68.29
50	42652.87	160	45	78.05
100	46004.98	155.75	49.25	75.97
150	46232.58	173.75	31.25	84.76
200	46851.92	175.5	29.5	85.61
250	54584.59	176.25	28.75	85.98
300	48814.35	170.5	34.5	83.17
350	50983.32	164.5	40.5	80.24
400	74384.43	177.5	27.5	86.59
450	56365.92	174.25	30.75	85
500	59102.46	149.5	55.5	72.93

Tabela 5.6: Wyniki badań dla sieci neuronowej składającej się z 5 warstw ukrytych, uczonej algorytmem zmiennej metryki.

5.3 Algorytm gradientów sprzężonych

W części tej zobrazowano wyniki badań dla algorytmu gradientów sprzężonych. W metodzie tej parametrami, jakie były zmieniane w celu określenia najlepszej jakości uczenia była liczba epok oraz współczynnik uczenia.

Sieć składająca się z jednej warstwy ukrytej

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja					
10	0.01	431.69	127	78	61.95
10	0.2	397.72	127	78	61.95
10	0.4	398.52	127	78	61.95
10	0.6	406.83	127	78	61.95
10	0.9	392.89	127	78	61.95
20	0.01	399.03	127	78	61.95
20	0.2	396.57	127	78	61.95
20	0.4	1378.26	127	78	61.95
20	0.6	420.77	127	78	61.95
20	0.9	411.4	127	78	61.95
50	0.01	420.67	127	78	61.95
50	0.2	415.28	127	78	61.95
50	0.4	416.82	127	78	61.95
50	0.6	418.27	131	74	63.9

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50	0.9	422.2	172	33	83.9
100	0.01	438.08	127	78	61.95
100	0.2	437.55	138	67	67.32
100	0.4	427.8	166	39	80.98
100	0.6	435.82	175	30	85.37
100	0.9	440.52	174	31	84.88
200	0.01	485.95	127	78	61.95
200	0.2	480.64	176	29	85.85
200	0.4	523.22	174	31	84.88
200	0.6	544.06	177	28	86.34
200	0.9	486.55	180	25	87.8
500	0.01	612.21	127	78	61.95
500	0.2	595.13	175	30	85.37
500	0.4	601.5	178	27	86.83
500	0.6	614.48	172	33	83.9
500	0.9	590.6	178	27	86.83
1000	0.01	1765.37	127	78	61.95
1000	0.2	814.65	177	28	86.34
1000	0.4	801.78	176	29	85.85
1000	0.6	780.67	127	78	61.95
1000	0.9	786.44	171	34	83.41
2000	0.01	1230.29	146	59	71.22
2000	0.2	1192.01	177	28	86.34
2000	0.4	1189.77	176	29	85.85
2000	0.6	1179.37	175	30	85.37
2000	0.9	1217.13	180	25	87.8
5000	0.01	2323.74	174	31	84.88
5000	0.2	2350.41	181	24	88.29
5000	0.4	3270.78	182	23	88.78
5000	0.6	2439.31	186	19	90.73
5000	0.9	2314.46	173	32	84.39
10000	0.01	4399.35	178	27	86.83
10000	0.2	4402.52	182	23	88.78
10000	0.4	4357.62	180	25	87.8
10000	0.6	4380.68	184	21	89.76
10000	0.9	4411.99	178	27	86.83
20000	0.01	8324.24	177	28	86.34
20000	0.2	8302.77	182	23	88.78
20000	0.4	8197.23	177	28	86.34
20000	0.6	8189.81	184	21	89.76
20000	0.9	8136.49	179	26	87.32
50000	0.01	20288.14	177	28	86.34
50000	0.2	20165.91	175	30	85.37
50000	0.4	20106.37	186	19	90.73

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50000	0.6	20285.31	184	21	89.76
50000	0.9	19875.61	189	16	92.2
Druga iteracja					
10	0.01	501.29	126	79	61.46
10	0.2	440.24	127	78	61.95
10	0.4	443.42	127	78	61.95
10	0.6	441.81	127	78	61.95
10	0.9	437.42	127	78	61.95
20	0.01	454.73	127	78	61.95
20	0.2	448.57	127	78	61.95
20	0.4	452.4	127	78	61.95
20	0.6	444.41	127	78	61.95
20	0.9	448.89	127	78	61.95
50	0.01	452.89	127	78	61.95
50	0.2	456.14	127	78	61.95
50	0.4	455.56	127	78	61.95
50	0.6	454.44	134	71	65.37
50	0.9	469.86	175	30	85.37
100	0.01	478.25	127	78	61.95
100	0.2	1738.84	172	33	83.9
100	0.4	494.69	173	32	84.39
100	0.6	500.13	177	28	86.34
100	0.9	487.85	169	36	82.44
200	0.01	524.66	127	78	61.95
200	0.2	526.87	174	31	84.88
200	0.4	530.46	173	32	84.39
200	0.6	537.2	175	30	85.37
200	0.9	534.64	139	66	67.8
500	0.01	642.83	127	78	61.95
500	0.2	642.59	177	28	86.34
500	0.4	639.65	174	31	84.88
500	0.6	643.4	177	28	86.34
500	0.9	642.13	177	28	86.34
1000	0.01	883.62	127	78	61.95
1000	0.2	888.65	177	28	86.34
1000	0.4	891.07	177	28	86.34
1000	0.6	871.76	173	32	84.39
1000	0.9	877.27	176	29	85.85
2000	0.01	1299.23	158	47	77.07
2000	0.2	1304.67	177	28	86.34
2000	0.4	1277.68	179	26	87.32
2000	0.6	1272.75	179	26	87.32
2000	0.9	1362.81	127	78	61.95
5000	0.01	2539.32	176	29	85.85

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
5000	0.2	2520.22	178	27	86.83
5000	0.4	3806.09	180	25	87.8
5000	0.6	2658.6	177	28	86.34
5000	0.9	2661.86	185	20	90.24
10000	0.01	4933.91	177	28	86.34
10000	0.2	4763.67	180	25	87.8
10000	0.4	4764.72	187	18	91.22
10000	0.6	4777.19	179	26	87.32
10000	0.9	5168.07	187	18	91.22
20000	0.01	9200.32	177	28	86.34
20000	0.2	8913.48	183	22	89.27
20000	0.4	8981.03	179	26	87.32
20000	0.6	8865.07	175	30	85.37
20000	0.9	8556.86	127	78	61.95
50000	0.01	22328.48	177	28	86.34
50000	0.2	22403.06	180	25	87.8
50000	0.4	21826.64	185	20	90.24
50000	0.6	22253.27	186	19	90.73
50000	0.9	21927.34	185	20	90.24
Trzecia iteracja					
10	0.01	439.82	127	78	61.95
10	0.2	435.77	127	78	61.95
10	0.4	438.83	127	78	61.95
10	0.6	421.42	127	78	61.95
10	0.9	413.19	127	78	61.95
20	0.01	593.91	127	78	61.95
20	0.2	594.99	127	78	61.95
20	0.4	627.44	127	78	61.95
20	0.6	601.84	127	78	61.95
20	0.9	2429.45	127	78	61.95
50	0.01	454.54	127	78	61.95
50	0.2	454.93	127	78	61.95
50	0.4	449.19	127	78	61.95
50	0.6	448.25	127	78	61.95
50	0.9	437.82	78	127	38.05
100	0.01	621.47	127	78	61.95
100	0.2	591.19	174	31	84.88
100	0.4	569.08	176	29	85.85
100	0.6	635.84	175	30	85.37
100	0.9	603.06	174	31	84.88
200	0.01	664.76	127	78	61.95
200	0.2	583.11	173	32	84.39
200	0.4	508.96	178	27	86.83
200	0.6	508.09	177	28	86.34

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
200	0.9	525.42	154	51	75.12
500	0.01	623.53	127	78	61.95
500	0.2	613.4	178	27	86.83
500	0.4	727.29	78	127	38.05
500	0.6	834.43	177	28	86.34
500	0.9	657.06	177	28	86.34
1000	0.01	1020.22	127	78	61.95
1000	0.2	960.4	177	28	86.34
1000	0.4	1754.78	177	28	86.34
1000	0.6	835.32	177	28	86.34
1000	0.9	830.13	179	26	87.32
2000	0.01	1657.4	127	78	61.95
2000	0.2	1347.02	177	28	86.34
2000	0.4	1445.83	175	30	85.37
2000	0.6	1215.28	180	25	87.8
2000	0.9	1132.98	127	78	61.95
5000	0.01	3009.81	175	30	85.37
5000	0.2	3276.59	175	30	85.37
5000	0.4	3298.4	180	25	87.8
5000	0.6	3131.07	183	22	89.27
5000	0.9	2583.08	180	25	87.8
10000	0.01	5563.04	177	28	86.34
10000	0.2	4720.01	181	24	88.29
10000	0.4	4773.66	183	22	89.27
10000	0.6	5051.21	179	26	87.32
10000	0.9	4496.2	127	78	61.95
20000	0.01	9121.54	177	28	86.34
20000	0.2	9096.41	186	19	90.73
20000	0.4	9899.82	183	22	89.27
20000	0.6	9205.44	181	24	88.29
20000	0.9	8764.9	127	78	61.95
50000	0.01	20961.08	177	28	86.34
50000	0.2	21407.24	187	18	91.22
50000	0.4	20631.8	186	19	90.73
50000	0.6	20732.65	178	27	86.83
50000	0.9	19457.3	127	78	61.95
Czwarta iteracja					
10	0.01	437.93	78	127	38.05
10	0.2	414.89	127	78	61.95
10	0.4	413.13	127	78	61.95
10	0.6	410.31	127	78	61.95
10	0.9	408.94	127	78	61.95
20	0.01	408.26	75	130	36.59
20	0.2	398.99	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20	0.4	411.41	127	78	61.95
20	0.6	409.83	127	78	61.95
20	0.9	413.41	127	78	61.95
50	0.01	413.41	127	78	61.95
50	0.2	419.69	127	78	61.95
50	0.4	1550.74	127	78	61.95
50	0.6	443.76	126	79	61.46
50	0.9	434.64	127	78	61.95
100	0.01	515.21	127	78	61.95
100	0.2	544.75	127	78	61.95
100	0.4	579.09	172	33	83.9
100	0.6	599.38	173	32	84.39
100	0.9	621.91	174	31	84.88
200	0.01	485.26	127	78	61.95
200	0.2	495.61	172	33	83.9
200	0.4	482.6	177	28	86.34
200	0.6	469.72	178	27	86.83
200	0.9	462.33	78	127	38.05
500	0.01	725.22	127	78	61.95
500	0.2	748.47	178	27	86.83
500	0.4	727.02	177	28	86.34
500	0.6	722.52	177	28	86.34
500	0.9	792.76	78	127	38.05
1000	0.01	928.75	127	78	61.95
1000	0.2	1016.33	177	28	86.34
1000	0.4	1324.0	177	28	86.34
1000	0.6	1523.34	176	29	85.85
1000	0.9	1263.19	177	28	86.34
2000	0.01	1156.98	157	48	76.59
2000	0.2	1505.83	177	28	86.34
2000	0.4	2615.17	177	28	86.34
2000	0.6	1991.41	181	24	88.29
2000	0.9	2030.36	183	22	89.27
5000	0.01	2472.8	175	30	85.37
5000	0.2	2413.23	179	26	87.32
5000	0.4	2382.29	179	26	87.32
5000	0.6	2366.7	182	23	88.78
5000	0.9	2187.64	127	78	61.95
10000	0.01	4269.82	178	27	86.83
10000	0.2	4271.34	181	24	88.29
10000	0.4	4274.83	186	19	90.73
10000	0.6	4182.08	178	27	86.83
10000	0.9	4240.24	184	21	89.76
20000	0.01	10008.08	178	27	86.83

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20000	0.2	9468.42	184	21	89.76
20000	0.4	8791.58	185	20	90.24
20000	0.6	9386.77	78	127	38.05
20000	0.9	9046.75	185	20	90.24
50000	0.01	20674.17	177	28	86.34
50000	0.2	22140.07	186	19	90.73
50000	0.4	21264.63	185	20	90.24
50000	0.6	20773.55	176	29	85.85
50000	0.9	21312.56	174	31	84.88
Uśrednione wyniki					
10	0.01	452.68	114.5	90.5	55.85
10	0.2	422.16	127	78	61.95
10	0.4	423.48	127	78	61.95
10	0.6	420.09	127	78	61.95
10	0.9	413.11	127	78	61.95
20	0.01	463.98	114	91	55.61
20	0.2	459.78	127	78	61.95
20	0.4	717.38	127	78	61.95
20	0.6	469.21	127	78	61.95
20	0.9	925.79	127	78	61.95
50	0.01	435.38	127	78	61.95
50	0.2	436.51	127	78	61.95
50	0.4	718.08	127	78	61.95
50	0.6	441.18	129.5	75.5	63.17
50	0.9	441.13	138	67	67.32
100	0.01	513.25	127	78	61.95
100	0.2	828.08	152.75	52.25	74.51
100	0.4	517.67	171.75	33.25	83.78
100	0.6	542.79	175	30	85.37
100	0.9	538.34	172.75	32.25	84.27
200	0.01	540.16	127	78	61.95
200	0.2	521.56	173.75	31.25	84.76
200	0.4	511.31	175.5	29.5	85.61
200	0.6	514.77	176.75	28.25	86.22
200	0.9	502.24	137.75	67.25	67.19
500	0.01	650.95	127	78	61.95
500	0.2	649.9	177	28	86.34
500	0.4	673.87	151.75	53.25	74.03
500	0.6	703.71	175.75	29.25	85.73
500	0.9	670.64	152.5	52.5	74.39
1000	0.01	1149.49	127	78	61.95
1000	0.2	920.01	177	28	86.34
1000	0.4	1192.91	176.75	28.25	86.22
1000	0.6	1002.77	163.25	41.75	79.63

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
1000	0.9	939.26	175.75	29.25	85.73
2000	0.01	1335.98	147	58	71.71
2000	0.2	1337.38	177	28	86.34
2000	0.4	1632.11	176.75	28.25	86.22
2000	0.6	1414.7	178.75	26.25	87.2
2000	0.9	1435.82	154.25	50.75	75.24
5000	0.01	2586.42	175	30	85.37
5000	0.2	2640.11	178.25	26.75	86.95
5000	0.4	3189.39	180.25	24.75	87.93
5000	0.6	2648.92	182	23	88.78
5000	0.9	2436.76	166.25	38.75	81.1
10000	0.01	4791.53	177.5	27.5	86.59
10000	0.2	4539.39	181	24	88.29
10000	0.4	4542.71	184	21	89.76
10000	0.6	4597.79	180	25	87.81
10000	0.9	4579.13	169	36	82.44
20000	0.01	9163.55	177.25	27.75	86.46
20000	0.2	8945.27	183.75	21.25	89.64
20000	0.4	8967.42	181	24	88.29
20000	0.6	8911.77	154.5	50.5	75.37
20000	0.9	8626.25	154.5	50.5	75.37
50000	0.01	21062.97	177	28	86.34
50000	0.2	21529.07	182	23	88.78
50000	0.4	20957.36	185.5	19.5	90.49
50000	0.6	21011.2	181	24	88.29
50000	0.9	20643.2	168.75	36.25	82.32

Tabela 5.7: Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem gradientów sprzężonych.

Sieć składająca się z trzech warstw ukrytych

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja					
10	0.01	648.11	127	78	61.95
10	0.2	634.41	127	78	61.95
10	0.4	628.3	127	78	61.95
10	0.6	1673.54	127	78	61.95
10	0.9	643.82	127	78	61.95
20	0.01	658.51	127	78	61.95
20	0.2	654.82	127	78	61.95
20	0.4	644.71	127	78	61.95
20	0.6	631.91	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20	0.9	635.73	127	78	61.95
50	0.01	656.89	127	78	61.95
50	0.2	661.84	127	78	61.95
50	0.4	655.8	127	78	61.95
50	0.6	660.45	127	78	61.95
50	0.9	660.08	127	78	61.95
100	0.01	1681.14	127	78	61.95
100	0.2	693.91	127	78	61.95
100	0.4	693.61	127	78	61.95
100	0.6	697.8	127	78	61.95
100	0.9	688.22	153	52	74.63
200	0.01	754.65	127	78	61.95
200	0.2	754.7	127	78	61.95
200	0.4	743.61	127	78	61.95
200	0.6	750.66	135	70	65.85
200	0.9	739.68	127	78	61.95
500	0.01	918.14	127	78	61.95
500	0.2	931.43	127	78	61.95
500	0.4	2041.67	110	95	53.66
500	0.6	904.11	127	78	61.95
500	0.9	945.75	132	73	64.39
1000	0.01	1288.27	127	78	61.95
1000	0.2	1223.88	78	127	38.05
1000	0.4	1198.63	125	80	60.98
1000	0.6	1375.81	171	34	83.41
1000	0.9	1163.85	127	78	61.95
2000	0.01	1787.21	127	78	61.95
2000	0.2	1763.82	78	127	38.05
2000	0.4	1816.05	177	28	86.34
2000	0.6	2641.38	127	78	61.95
2000	0.9	1698.93	127	78	61.95
5000	0.01	3643.29	180	25	87.8
5000	0.2	3526.24	127	78	61.95
5000	0.4	3121.97	127	78	61.95
5000	0.6	3130.12	127	78	61.95
5000	0.9	3093.18	127	78	61.95
10000	0.01	6499.75	127	78	61.95
10000	0.2	6218.07	78	127	38.05
10000	0.4	6139.07	127	78	61.95
10000	0.6	5867.76	127	78	61.95
10000	0.9	6411.8	127	78	61.95
20000	0.01	12222.38	177	28	86.34
20000	0.2	14358.49	78	127	38.05
20000	0.4	12554.67	179	26	87.32

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
20000	0.6	11079.93	127	78	61.95
20000	0.9	10565.26	127	78	61.95
50000	0.01	29684.39	179	26	87.32
50000	0.2	29378.15	127	78	61.95
50000	0.4	29331.59	173	32	84.39
50000	0.6	35463.49	82	123	40.0
50000	0.9	25999.64	127	78	61.95
Druga iteracja					
10	0.01	1797.86	127	78	61.95
10	0.2	720.73	127	78	61.95
10	0.4	731.28	127	78	61.95
10	0.6	709.36	127	78	61.95
10	0.9	712.66	127	78	61.95
20	0.01	706.2	78	127	38.05
20	0.2	715.05	127	78	61.95
20	0.4	701.86	127	78	61.95
20	0.6	699.39	127	78	61.95
20	0.9	693.98	127	78	61.95
50	0.01	709.41	127	78	61.95
50	0.2	1814.24	127	78	61.95
50	0.4	734.79	127	78	61.95
50	0.6	735.46	127	78	61.95
50	0.9	728.59	127	78	61.95
100	0.01	786.59	127	78	61.95
100	0.2	769.82	127	78	61.95
100	0.4	770.86	127	78	61.95
100	0.6	777.81	127	78	61.95
100	0.9	772.26	127	78	61.95
200	0.01	830.4	127	78	61.95
200	0.2	824.78	127	78	61.95
200	0.4	852.18	127	78	61.95
200	0.6	877.76	127	78	61.95
200	0.9	1984.82	172	33	83.9
500	0.01	2140.68	127	78	61.95
500	0.2	1043.36	175	30	85.37
500	0.4	1040.04	131	74	63.9
500	0.6	997.88	127	78	61.95
500	0.9	1020.87	127	78	61.95
1000	0.01	1358.57	127	78	61.95
1000	0.2	1332.6	127	78	61.95
1000	0.4	1322.55	136	69	66.34
1000	0.6	1363.95	78	127	38.05
1000	0.9	2177.8	78	127	38.05
2000	0.01	1952.46	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
2000	0.2	2803.19	160	45	78.05
2000	0.4	3035.66	78	127	38.05
2000	0.6	1988.57	127	78	61.95
2000	0.9	3346.11	172	33	83.9
5000	0.01	3962.2	127	78	61.95
5000	0.2	3695.74	127	78	61.95
5000	0.4	4235.66	165	40	80.49
5000	0.6	3502.31	127	78	61.95
5000	0.9	3589.45	172	33	83.9
10000	0.01	7119.46	127	78	61.95
10000	0.2	7102.97	180	25	87.8
10000	0.4	6958.73	176	29	85.85
10000	0.6	6742.15	127	78	61.95
10000	0.9	6057.28	127	78	61.95
20000	0.01	13263.7	176	29	85.85
20000	0.2	13670.13	78	127	38.05
20000	0.4	13675.65	78	127	38.05
20000	0.6	19517.36	121	84	59.02
20000	0.9	17750.05	169	36	82.44
50000	0.01	32871.71	180	25	87.8
50000	0.2	33561.71	78	127	38.05
50000	0.4	45024.43	127	78	61.95
50000	0.6	27216.08	127	78	61.95
50000	0.9	43293.84	171	34	83.41
Trzecia iteracja					
10	0.01	642.02	78	127	38.05
10	0.2	726.88	127	78	61.95
10	0.4	728.66	127	78	61.95
10	0.6	826.3	127	78	61.95
10	0.9	1977.86	127	78	61.95
20	0.01	1735.68	78	127	38.05
20	0.2	930.78	127	78	61.95
20	0.4	869.16	127	78	61.95
20	0.6	791.64	127	78	61.95
20	0.9	771.4	127	78	61.95
50	0.01	712.03	127	78	61.95
50	0.2	701.59	127	78	61.95
50	0.4	703.78	127	78	61.95
50	0.6	946.75	127	78	61.95
50	0.9	899.68	127	78	61.95
100	0.01	782.63	127	78	61.95
100	0.2	1766.41	127	78	61.95
100	0.4	765.89	127	78	61.95
100	0.6	779.49	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
100	0.9	803.13	127	78	61.95
200	0.01	755.09	127	78	61.95
200	0.2	796.33	127	78	61.95
200	0.4	767.67	127	78	61.95
200	0.6	783.72	137	68	66.83
200	0.9	741.99	127	78	61.95
500	0.01	947.26	127	78	61.95
500	0.2	933.91	127	78	61.95
500	0.4	939.19	171	34	83.41
500	0.6	1954.13	127	78	61.95
500	0.9	935.77	129	76	62.93
1000	0.01	1259.49	127	78	61.95
1000	0.2	1256.94	176	29	85.85
1000	0.4	1937.6	127	78	61.95
1000	0.6	1156.85	127	78	61.95
1000	0.9	1141.43	127	78	61.95
2000	0.01	1933.59	127	78	61.95
2000	0.2	1917.7	127	78	61.95
2000	0.4	1853.25	155	50	75.61
2000	0.6	1958.74	127	78	61.95
2000	0.9	2761.04	78	127	38.05
5000	0.01	3602.28	127	78	61.95
5000	0.2	4999.75	78	127	38.05
5000	0.4	3978.46	127	78	61.95
5000	0.6	4076.72	127	78	61.95
5000	0.9	4039.1	127	78	61.95
10000	0.01	7064.2	127	78	61.95
10000	0.2	10194.02	171	34	83.41
10000	0.4	8958.77	78	127	38.05
10000	0.6	7782.93	170	35	82.93
10000	0.9	6043.28	127	78	61.95
20000	0.01	12476.0	176	29	85.85
20000	0.2	12432.95	179	26	87.32
20000	0.4	11283.48	127	78	61.95
20000	0.6	20031.44	127	78	61.95
20000	0.9	10709.6	127	78	61.95
50000	0.01	34905.28	180	25	87.8
50000	0.2	32731.61	177	28	86.34
50000	0.4	48336.47	172	33	83.9
50000	0.6	27986.22	127	78	61.95
50000	0.9	40525.54	127	78	61.95
Czwarta iteracja					
10	0.01	648.68	78	127	38.05
10	0.2	646.7	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10	0.4	660.02	127	78	61.95
10	0.6	648.57	127	78	61.95
10	0.9	641.5	127	78	61.95
20	0.01	647.62	78	127	38.05
20	0.2	647.15	127	78	61.95
20	0.4	1641.71	127	78	61.95
20	0.6	662.56	127	78	61.95
20	0.9	652.71	127	78	61.95
50	0.01	681.25	127	78	61.95
50	0.2	687.26	127	78	61.95
50	0.4	671.0	127	78	61.95
50	0.6	672.59	127	78	61.95
50	0.9	679.87	127	78	61.95
100	0.01	976.31	127	78	61.95
100	0.2	1035.3	127	78	61.95
100	0.4	1074.76	127	78	61.95
100	0.6	1193.65	127	78	61.95
100	0.9	944.66	127	78	61.95
200	0.01	1935.45	127	78	61.95
200	0.2	1168.13	127	78	61.95
200	0.4	1205.67	158	47	77.07
200	0.6	1182.09	78	127	38.05
200	0.9	1086.7	134	71	65.37
500	0.01	1439.83	127	78	61.95
500	0.2	1219.76	127	78	61.95
500	0.4	1293.08	127	78	61.95
500	0.6	1085.55	127	78	61.95
500	0.9	1119.07	178	27	86.83
1000	0.01	1718.89	127	78	61.95
1000	0.2	2024.72	136	69	66.34
1000	0.4	1840.92	127	78	61.95
1000	0.6	3792.15	137	68	66.83
1000	0.9	2109.13	170	35	82.93
2000	0.01	2908.43	127	78	61.95
2000	0.2	2710.72	127	78	61.95
2000	0.4	2335.64	127	78	61.95
2000	0.6	2670.79	137	68	66.83
2000	0.9	1682.83	127	78	61.95
5000	0.01	3592.91	127	78	61.95
5000	0.2	3566.56	127	78	61.95
5000	0.4	3434.72	127	78	61.95
5000	0.6	3258.77	127	78	61.95
5000	0.9	4221.68	78	127	38.05
10000	0.01	6332.12	176	29	85.85

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10000	0.2	8304.26	127	78	61.95
10000	0.4	5645.33	127	78	61.95
10000	0.6	5613.33	127	78	61.95
10000	0.9	8126.14	34	171	16.59
20000	0.01	12728.15	177	28	86.34
20000	0.2	25597.94	170	35	82.93
20000	0.4	12319.32	165	40	80.49
20000	0.6	11356.71	127	78	61.95
20000	0.9	12772.71	78	127	38.05
50000	0.01	32154.84	180	25	87.8
50000	0.2	40230.37	127	78	61.95
50000	0.4	34523.44	127	78	61.95
50000	0.6	25563.69	127	78	61.95
50000	0.9	28547.0	127	78	61.95
Uśrednione wyniki					
10	0.01	934.17	102.5	102.5	50
10	0.2	682.18	127	78	61.95
10	0.4	687.07	127	78	61.95
10	0.6	964.44	127	78	61.95
10	0.9	993.96	127	78	61.95
20	0.01	937	90.25	114.75	44.03
20	0.2	736.95	127	78	61.95
20	0.4	964.36	127	78	61.95
20	0.6	696.38	127	78	61.95
20	0.9	688.46	127	78	61.95
50	0.01	689.9	127	78	61.95
50	0.2	966.23	127	78	61.95
50	0.4	691.34	127	78	61.95
50	0.6	753.81	127	78	61.95
50	0.9	742.06	127	78	61.95
100	0.01	1056.67	127	78	61.95
100	0.2	1066.36	127	78	61.95
100	0.4	826.28	127	78	61.95
100	0.6	862.19	127	78	61.95
100	0.9	802.07	133.5	71.5	65.12
200	0.01	1068.9	127	78	61.95
200	0.2	885.99	127	78	61.95
200	0.4	892.28	134.75	70.25	65.73
200	0.6	898.56	119.25	85.75	58.17
200	0.9	1138.3	140	65	68.29
500	0.01	1361.48	127	78	61.95
500	0.2	1032.12	139	66	67.81
500	0.4	1328.5	134.75	70.25	65.73
500	0.6	1235.42	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
500	0.9	1005.37	141.5	63.5	69.03
1000	0.01	1406.31	127	78	61.95
1000	0.2	1459.54	129.25	75.75	63.05
1000	0.4	1574.93	128.75	76.25	62.81
1000	0.6	1922.19	128.25	76.75	62.56
1000	0.9	1648.05	125.5	79.5	61.22
2000	0.01	2145.42	127	78	61.95
2000	0.2	2298.86	123	82	60
2000	0.4	2260.15	134.25	70.75	65.49
2000	0.6	2314.87	129.5	75.5	63.17
2000	0.9	2372.23	126	79	61.46
5000	0.01	3700.17	140.25	64.75	68.41
5000	0.2	3947.07	114.75	90.25	55.98
5000	0.4	3692.7	136.5	68.5	66.59
5000	0.6	3491.98	127	78	61.95
5000	0.9	3735.85	126	79	61.46
10000	0.01	6753.88	139.25	65.75	67.93
10000	0.2	7954.83	139	66	67.8
10000	0.4	6925.48	127	78	61.95
10000	0.6	6501.54	137.75	67.25	67.2
10000	0.9	6659.63	103.75	101.25	50.61
20000	0.01	12672.56	176.5	28.5	86.1
20000	0.2	16514.88	126.25	78.75	61.59
20000	0.4	12458.28	137.25	67.75	66.95
20000	0.6	15496.36	125.5	79.5	61.22
20000	0.9	12949.41	125.25	79.75	61.1
50000	0.01	32404.06	179.75	25.25	87.68
50000	0.2	33975.46	127.25	77.75	62.07
50000	0.4	39303.98	149.75	55.25	73.05
50000	0.6	29057.37	115.75	89.25	56.46
50000	0.9	34591.51	138	67	67.32

Tabela 5.8: Wyniki badań dla sieci neuronowej składającej się z 3 warstw ukrytych, uczonej algorytmem gradientów sprzężonych.

Sieć składająca się z pięciu warstw ukrytych

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
Pierwsza iteracja					
10	0.01	903.29	127	78	61.95
10	0.2	886.19	127	78	61.95
10	0.4	878.97	127	78	61.95
10	0.6	878.64	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10	0.9	876.8	127	78	61.95
20	0.01	888.7	78	127	38.05
20	0.2	882.57	127	78	61.95
20	0.4	880.72	127	78	61.95
20	0.6	2127.45	127	78	61.95
20	0.9	904.43	127	78	61.95
50	0.01	1923.06	127	78	61.95
50	0.2	926.38	127	78	61.95
50	0.4	924.52	127	78	61.95
50	0.6	917.49	127	78	61.95
50	0.9	913.87	127	78	61.95
100	0.01	956.65	127	78	61.95
100	0.2	949.19	127	78	61.95
100	0.4	953.26	127	78	61.95
100	0.6	944.78	127	78	61.95
100	0.9	1997.08	127	78	61.95
200	0.01	1016.75	127	78	61.95
200	0.2	2129.98	127	78	61.95
200	0.4	1046.62	127	78	61.95
200	0.6	1038.14	127	78	61.95
200	0.9	1072.1	127	78	61.95
500	0.01	1304.35	127	78	61.95
500	0.2	1279.53	127	78	61.95
500	0.4	1255.62	127	78	61.95
500	0.6	1254.31	127	78	61.95
500	0.9	1278.34	127	78	61.95
1000	0.01	1625.5	127	78	61.95
1000	0.2	1611.75	127	78	61.95
1000	0.4	2745.94	127	78	61.95
1000	0.6	1647.13	127	78	61.95
1000	0.9	1700.19	127	78	61.95
2000	0.01	2426.8	127	78	61.95
2000	0.2	2454.11	127	78	61.95
2000	0.4	2405.87	127	78	61.95
2000	0.6	2228.97	127	78	61.95
2000	0.9	2232.19	127	78	61.95
5000	0.01	4657.23	127	78	61.95
5000	0.2	4639.35	127	78	61.95
5000	0.4	4642.73	127	78	61.95
5000	0.6	5467.85	127	78	61.95
5000	0.9	4208.75	127	78	61.95
10000	0.01	9655.35	127	78	61.95
10000	0.2	8447.79	127	78	61.95
10000	0.4	7521.73	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
10000	0.6	7538.35	127	78	61.95
10000	0.9	7117.89	78	127	38.05
20000	0.01	16412.03	127	78	61.95
20000	0.2	13802.2	127	78	61.95
20000	0.4	31683.3	127	78	61.95
20000	0.6	22145.26	172	33	83.9
20000	0.9	14991.56	127	78	61.95
50000	0.01	38770.49	127	78	61.95
50000	0.2	40250.78	157	48	76.59
50000	0.4	45390.28	140	65	68.29
50000	0.6	78788.44	131	74	63.9
50000	0.9	32722.49	127	78	61.95
Druga iteracja					
10	0.01	981.3	78	127	38.05
10	0.2	984.94	127	78	61.95
10	0.4	998.05	127	78	61.95
10	0.6	2053.87	127	78	61.95
10	0.9	1011.27	127	78	61.95
20	0.01	2086.85	127	78	61.95
20	0.2	1034.11	127	78	61.95
20	0.4	996.29	127	78	61.95
20	0.6	981.05	127	78	61.95
20	0.9	993.87	127	78	61.95
50	0.01	1046.43	127	78	61.95
50	0.2	1009.98	127	78	61.95
50	0.4	997.12	127	78	61.95
50	0.6	994.21	127	78	61.95
50	0.9	991.1	127	78	61.95
100	0.01	1059.19	127	78	61.95
100	0.2	1062.17	127	78	61.95
100	0.4	1041.82	127	78	61.95
100	0.6	2347.31	127	78	61.95
100	0.9	1078.67	127	78	61.95
200	0.01	1158.79	127	78	61.95
200	0.2	1155.1	127	78	61.95
200	0.4	1148.43	127	78	61.95
200	0.6	1138.97	127	78	61.95
200	0.9	1151.33	127	78	61.95
500	0.01	1397.7	127	78	61.95
500	0.2	1384.28	127	78	61.95
500	0.4	1366.73	127	78	61.95
500	0.6	1378.12	127	78	61.95
500	0.9	2668.99	127	78	61.95
1000	0.01	1842.88	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
1000	0.2	3418.6	127	78	61.95
1000	0.4	2186.69	127	78	61.95
1000	0.6	1849.31	127	78	61.95
1000	0.9	1805.53	127	78	61.95
2000	0.01	2675.54	127	78	61.95
2000	0.2	2674.38	127	78	61.95
2000	0.4	2671.59	127	78	61.95
2000	0.6	2639.7	127	78	61.95
2000	0.9	2413.76	127	78	61.95
5000	0.01	5244.76	127	78	61.95
5000	0.2	4867.2	127	78	61.95
5000	0.4	4596.34	127	78	61.95
5000	0.6	6077.41	127	78	61.95
5000	0.9	5804.42	127	78	61.95
10000	0.01	10747.81	127	78	61.95
10000	0.2	8600.14	127	78	61.95
10000	0.4	11486.34	148	57	72.2
10000	0.6	8431.33	127	78	61.95
10000	0.9	8034.49	127	78	61.95
20000	0.01	21830.21	127	78	61.95
20000	0.2	19020.35	127	78	61.95
20000	0.4	14885.57	127	78	61.95
20000	0.6	14697.88	127	78	61.95
20000	0.9	16778.81	127	78	61.95
50000	0.01	53392.14	127	78	61.95
50000	0.2	71660.37	142	63	69.27
50000	0.4	51447.64	160	45	78.05
50000	0.6	34629.51	127	78	61.95
50000	0.9	34381.71	127	78	61.95
Trzecia iteracja					
10	0.01	1768.52	78	127	38.05
10	0.2	1756.76	127	78	61.95
10	0.4	1452.5	127	78	61.95
10	0.6	1365.44	127	78	61.95
10	0.9	1287.59	127	78	61.95
20	0.01	1055.62	127	78	61.95
20	0.2	1047.62	127	78	61.95
20	0.4	1123.0	127	78	61.95
20	0.6	2621.98	127	78	61.95
20	0.9	1407.32	127	78	61.95
50	0.01	1193.79	127	78	61.95
50	0.2	2175.33	127	78	61.95
50	0.4	989.07	127	78	61.95
50	0.6	996.89	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50	0.9	1117.92	127	78	61.95
100	0.01	1335.4	127	78	61.95
100	0.2	1305.96	127	78	61.95
100	0.4	1029.52	127	78	61.95
100	0.6	1107.99	127	78	61.95
100	0.9	2360.22	127	78	61.95
200	0.01	1049.22	127	78	61.95
200	0.2	1209.69	127	78	61.95
200	0.4	2935.16	127	78	61.95
200	0.6	1452.34	127	78	61.95
200	0.9	1080.43	127	78	61.95
500	0.01	1298.79	127	78	61.95
500	0.2	1290.3	127	78	61.95
500	0.4	1288.5	127	78	61.95
500	0.6	1295.38	127	78	61.95
500	0.9	1287.88	127	78	61.95
1000	0.01	1654.64	127	78	61.95
1000	0.2	1669.08	127	78	61.95
1000	0.4	1667.53	127	78	61.95
1000	0.6	2984.06	127	78	61.95
1000	0.9	2113.07	159	46	77.56
2000	0.01	2590.63	127	78	61.95
2000	0.2	4574.65	127	78	61.95
2000	0.4	2908.85	127	78	61.95
2000	0.6	3690.72	176	29	85.85
2000	0.9	3121.59	159	46	77.56
5000	0.01	6387.78	127	78	61.95
5000	0.2	7507.19	136	69	66.34
5000	0.4	5569.49	131	74	63.9
5000	0.6	6901.29	142	63	69.27
5000	0.9	8670.38	78	127	38.05
10000	0.01	9303.6	127	78	61.95
10000	0.2	9973.73	159	46	77.56
10000	0.4	10700.13	127	78	61.95
10000	0.6	10521.21	170	35	82.93
10000	0.9	16421.77	158	47	77.07
20000	0.01	16346.61	127	78	61.95
20000	0.2	14011.82	127	78	61.95
20000	0.4	15587.63	161	44	78.54
20000	0.6	14005.84	127	78	61.95
20000	0.9	14994.53	127	78	61.95
50000	0.01	45035.92	127	78	61.95
50000	0.2	48797.58	78	127	38.05
50000	0.4	36297.18	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
50000	0.6	46765.91	173	32	84.39
50000	0.9	34556.72	127	78	61.95
Czwarta iteracja					
10	0.01	922.75	78	127	38.05
10	0.2	1965.29	127	78	61.95
10	0.4	975.66	127	78	61.95
10	0.6	906.86	127	78	61.95
10	0.9	905.5	127	78	61.95
20	0.01	908.43	127	78	61.95
20	0.2	919.1	127	78	61.95
20	0.4	916.65	127	78	61.95
20	0.6	892.47	127	78	61.95
20	0.9	883.85	127	78	61.95
50	0.01	960.3	127	78	61.95
50	0.2	1237.33	127	78	61.95
50	0.4	1279.68	127	78	61.95
50	0.6	2654.55	127	78	61.95
50	0.9	1036.81	127	78	61.95
100	0.01	2583.41	127	78	61.95
100	0.2	1031.43	127	78	61.95
100	0.4	1026.08	127	78	61.95
100	0.6	1082.96	127	78	61.95
100	0.9	987.98	127	78	61.95
200	0.01	1064.9	127	78	61.95
200	0.2	1327.4	127	78	61.95
200	0.4	1371.92	127	78	61.95
200	0.6	1583.59	127	78	61.95
200	0.9	2464.3	127	78	61.95
500	0.01	1464.49	127	78	61.95
500	0.2	1387.85	127	78	61.95
500	0.4	2512.06	127	78	61.95
500	0.6	1352.65	127	78	61.95
500	0.9	1543.37	127	78	61.95
1000	0.01	2132.75	127	78	61.95
1000	0.2	2969.99	127	78	61.95
1000	0.4	2317.83	127	78	61.95
1000	0.6	2445.93	127	78	61.95
1000	0.9	1751.41	127	78	61.95
2000	0.01	2951.72	127	78	61.95
2000	0.2	3721.16	127	78	61.95
2000	0.4	4267.38	176	29	85.85
2000	0.6	4285.26	127	78	61.95
2000	0.9	2712.67	175	30	85.37
5000	0.01	6563.67	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
5000	0.2	4942.88	127	78	61.95
5000	0.4	4256.74	171	34	83.41
5000	0.6	5702.04	127	78	61.95
5000	0.9	4099.14	127	78	61.95
10000	0.01	8547.91	127	78	61.95
10000	0.2	7581.06	127	78	61.95
10000	0.4	8208.77	127	78	61.95
10000	0.6	14422.68	154	51	75.12
10000	0.9	12572.04	127	78	61.95
20000	0.01	17139.42	127	78	61.95
20000	0.2	30249.16	173	32	84.39
20000	0.4	20441.96	127	78	61.95
20000	0.6	14591.15	127	78	61.95
20000	0.9	14675.37	127	78	61.95
50000	0.01	41686.06	176	29	85.85
50000	0.2	48710.26	153	52	74.63
50000	0.4	63458.27	78	127	38.05
50000	0.6	32398.3	127	78	61.95
50000	0.9	32378.24	127	78	61.95
Uśrednione wyniki					
10	0.01	1143.97	90.25	114.75	44.03
10	0.2	1398.3	127	78	61.95
10	0.4	1076.3	127	78	61.95
10	0.6	1301.2	127	78	61.95
10	0.9	1020.29	127	78	61.95
20	0.01	1234.9	114.75	90.25	55.98
20	0.2	970.85	127	78	61.95
20	0.4	979.17	127	78	61.95
20	0.6	1655.74	127	78	61.95
20	0.9	1047.37	127	78	61.95
50	0.01	1280.9	127	78	61.95
50	0.2	1337.26	127	78	61.95
50	0.4	1047.6	127	78	61.95
50	0.6	1390.79	127	78	61.95
50	0.9	1014.93	127	78	61.95
100	0.01	1483.66	127	78	61.95
100	0.2	1087.19	127	78	61.95
100	0.4	1012.67	127	78	61.95
100	0.6	1370.76	127	78	61.95
100	0.9	1605.99	127	78	61.95
200	0.01	1072.42	127	78	61.95
200	0.2	1455.54	127	78	61.95
200	0.4	1625.53	127	78	61.95
200	0.6	1303.26	127	78	61.95

Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane	Niepoprawnie sklasyfikowane	Poprawnie sklasyfikowane [%]
200	0.9	1442.04	127	78	61.95
500	0.01	1366.33	127	78	61.95
500	0.2	1335.49	127	78	61.95
500	0.4	1605.73	127	78	61.95
500	0.6	1320.12	127	78	61.95
500	0.9	1694.65	127	78	61.95
1000	0.01	1813.94	127	78	61.95
1000	0.2	2417.36	127	78	61.95
1000	0.4	2229.5	127	78	61.95
1000	0.6	2231.61	127	78	61.95
1000	0.9	1842.55	135	70	65.85
2000	0.01	2661.17	127	78	61.95
2000	0.2	3356.08	127	78	61.95
2000	0.4	3063.42	139.25	65.75	67.93
2000	0.6	3211.16	139.25	65.75	67.93
2000	0.9	2620.05	147	58	71.71
5000	0.01	5713.36	127	78	61.95
5000	0.2	5489.16	129.25	75.75	63.05
5000	0.4	4766.33	139	66	67.8
5000	0.6	6037.15	130.75	74.25	63.78
5000	0.9	5695.67	114.75	90.25	55.98
10000	0.01	9563.67	127	78	61.95
10000	0.2	8650.68	135	70	65.85
10000	0.4	9479.24	132.25	72.75	64.51
10000	0.6	10228.39	144.5	60.5	70.49
10000	0.9	11036.55	122.5	82.5	59.76
20000	0.01	17932.07	127	78	61.95
20000	0.2	19270.88	138.5	66.5	67.56
20000	0.4	20649.62	135.5	69.5	66.1
20000	0.6	16360.03	138.25	66.75	67.44
20000	0.9	15360.07	127	78	61.95
50000	0.01	44721.15	139.25	65.75	67.93
50000	0.2	52354.75	132.5	72.5	64.64
50000	0.4	49148.34	126.25	78.75	61.59
50000	0.6	48145.54	139.5	65.5	68.05
50000	0.9	33509.79	127	78	61.95

Tabela 5.9: Wyniki badań dla sieci neuronowej składającej się z 5 warstw ukrytych, uczonej algorytmem gradientów sprzężonych.

5.4 Porównanie wyników

W części tej postanowiono porównać najlepsze z wyników przeprowadzonych badań poszczególnych algorytmów. Poniższa tabela ma na celu zobrazowanie różnic w wynikach jakie osiągała sieć po nauczaniu różnymi metodami. Zostały w niej zawarte dane z uśred-

nionych pomiarów ze wszystkich 4 iteracji.

Nazwa algorytmu	Liczba epok	Współczynnik uczenia	Czas uczenia [ms]	Poprawnie sklasyfikowane [%]
Sieć neuronowa z jedną warstwą ukrytą				
Wstecznej propagacji błędów	50000	0.9	16797.03	88.66
Zmiennej metryki	100	-	17741.87	87.44
Gradientów sprzężonych	50000	0.4	20957.36	90.49
Sieć neuronowa z trzema warstwami ukrytymi				
Wstecznej propagacji błędów	50000	0.4	27106.15	87.56
Zmiennej metryki	100	-	29317.22	86.59
Gradientów sprzężonych	50000	0.01	32404.06	87.68
Sieć neuronowa z pięcioma warstwami ukrytymi				
Wstecznej propagacji błędów	50000	0.9	33755.31	73.66
Zmiennej metryki	400	-	74384.43	86.59
Gradientów sprzężonych	2000	0.9	2620.05	71.71

Tabela 5.10: Porównanie najlepszych wyników pod względem jakości klasyfikacji.

Rozdział 6

Podsumowanie

Bibliografia

Książki

- [1] S. Osowski. *Sieci neuronowe w ujęciu algorytmicznym*. WNT, Warszawa, 1997.
- [2] D. Rutkowska, L. Rutkowski, M. Piliński. *Sieci neuronowe, algorytmy genetyczne i systemy rozmyte*. PWN, Warszawa, 1996.
- [3] R. Tadeusiewicz. *Sieci neuronowe*. Akademicka Oficyna Wydawnicza RM, Warszawa, 1993.
- [4] J. M. Żurada, M. Barski, W. Jędruch. *Sztuczne sieci neuronowe*. PWN, Warszawa, 1996.

Źródła internetowe

- [5] Artykuł o badaniach przesiewowych. <http://onko-med.pl/diagnostyka/badania-przesiewowe> (dostęp 12.04.2018).
- [6] Artykuł o inteligentnych technikach analizy danych. <http://www.labportal.pl/article/inteligentne-techniki-analizy-danych> (dostęp 24.03.2018).
- [7] Artykuł o metodach uczenia sieci neuronowej. http://www.neurosoft.edu.pl/media/pdf/tkwater/sztuczna_inteligencja/2_alg_ucz_ssn.pdf (dostęp 04.01.2018).
- [8] Artykuł o nowotworze piersi. <https://portal.abczdrowie.pl/rak-piersi> (dostęp 12.04.2018).
- [9] Prezentacja o sieciach neuronowych. http://www.neurosoft.edu.pl/media/pdf/jbartman/sztuczna_inteligencja/NTI9.pdf (dostęp 24.03.2018).
- [10] Wykład o sieciach neuronowych. <http://galaxy.uci.agh.edu.pl/~vlasi/AI/wstep/> (dostęp 04.01.2018).
- [11] Wykład o sieciach neuronowych. <http://www.mini.pw.edu.pl/MiniWyklady/sieci/modele/modele.html> (dostęp 24.03.2018).
- [12] Wykład o uczeniu sieci wielowarstwowych. http://www.neurosoft.edu.pl/media/pdf/jbartman/sztuczna_inteligencja/NTI%20cwiczenie_5.pdf (dostęp 24.03.2018).

- [13] Zbiór danych wykorzystany do uczenia sieci neuronowej. <https://archive.ics.uci.edu/ml/machine-learning-databases/breast-cancer-wisconsin/breast-cancer-wisconsin.data> (dostęp 12.04.2018).
- [14] Artykuł o uczeniu nadzorowanym i nienadzorowanym. <http://infoworker.no/2017/07/machine-learning-explained-by-ahmad-najjar/> (dostęp 04.01.2018).
- [15] Artykuł o uczeniu nadzorowanym i nienadzorowanym. <http://www.poltynk.pl/marcin/uczenie.html> (dostęp 04.01.2018).
- [16] Wykład o sieciach neuronowych. <http://sknbo.ue.poznan.pl/neuro/ssn/pliki/strukt/strukt1.html> (dostęp 04.01.2018).

Spis rysunków

2.1	Porównanie zdrowej piersi z zainfekowaną przez nowotwór	5
3.1	Biologiczny model neuronu	10
3.2	Sztuczny model neuronu	11
3.3	Przykładowa struktura sieci jednokierunkowej	12
3.4	Przykładowa struktura sieci rekurencyjnej	13
3.5	Przykładowa struktura sieci komórkowej	13
3.6	Schemat uczenia nadzorowanego	14
3.7	Schemat sieci realizującej uczenie metodą wstecznej propagacji błędów . .	16
3.8	Schemat sztucznej sieci neuronowej jednokierunkowej dwuwarstwowej . . .	17
4.1	Pokazanie wszystkich aplikacji o programie.	27
4.2	Przykładowe działania uruchomionej aplikacji.	27
4.3	Przykładowy wykres rysowany przez aplikację, który pokazuje jak zmienia- ła się wartość błędu w trakcie uczenia sieci.	28

Spis tabel

4.1	Opis możliwych parametrów przy egzekucji programu.	27
5.1	Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem wstecznej propagacji błędów.	36
5.2	Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem wstecznej propagacji błędów.	43
5.3	Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem wstecznej propagacji błędów.	50
5.4	Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem zmiennej metryki.	52
5.5	Wyniki badań dla sieci neuronowej składającej się z 3 warstw ukrytych, uczonej algorytmem zmiennej metryki.	54
5.6	Wyniki badań dla sieci neuronowej składającej się z 5 warstw ukrytych, uczonej algorytmem zmiennej metryki.	56
5.7	Wyniki badań dla sieci neuronowej składającej się z 1 warstwy ukrytej, uczonej algorytmem gradientów sprzężonych.	63
5.8	Wyniki badań dla sieci neuronowej składającej się z 3 warstw ukrytych, uczonej algorytmem gradientów sprzężonych.	70
5.9	Wyniki badań dla sieci neuronowej składającej się z 5 warstw ukrytych, uczonej algorytmem gradientów sprzężonych.	77
5.10	Porównanie najlepszych wyników pod względem jakości klasyfikacji.	78