

IZABELA SKRZYPCZAK, DAWID ZIENTEK\*

## WYKORZYSTANIE SIECI NEURONOWYCH DO ODWZOROWANIA DEFORMACJI POWIERZCHNI NA TERENACH GÓRNICZYCH

---

## THE APPLICATION OF NEURAL NETWORKS FOR PROJECTION OF SURFACES DEFORMATIONS ON MINING AREAS

### Streszczenie

W artykule przedstawiono metody wykorzystania sztucznych sieci neuronowych do oceny przemieszczeń pionowych na obszarze górniczym „Bieruń” I. Sieci te były uczone i testowane na podstawie danych pomiarowych pochodzących z KWK „PIAST” wykonanych w 2004 r.

*Słowa kluczowe: sieci neuronowe, prognozowanie deformacji, odwzorowanie*

### Abstract

In the paper the methods of application of artificial neural networks for the assessment of vertical dislocations on the mining area of Bieruń I were presented. The networks were learnt and tested on the basis of the survey data done in the coalmine PIAST in the year 2004.

*Keywords: neural networks, deformation forecast, projection*

---

\* Dr inż. Izabela Skrzypczak, mgr Dawid Zientek, Katedra Geodezji, Wydział Budownictwa i Inżynierii Środowiska, Politechnika Rzeszowska.

## 1. Wstęp

Sztuczne sieci neuronowe są coraz częściej wykorzystywane do rozwiązywania różnych problemów w inżynierii lądowej [1–3]. Używane są przede wszystkim jako narzędzie przydatne przy kojarzeniu ze sobą wielu parametrów oraz identyfikowaniu i predykcji na tej podstawie innych cech. Cechą tą może być np. przemieszczenie pionowe kontrolowane w trakcie eksploatacji na terenach górniczych.

W tym celu zbudowano zbiór danych przeznaczony do uczenia i testowania sieci neuronowych. Nauczono i przetestowano te sieci oraz opracowano metodykę neuronowej identyfikacji przemieszczeń pionowych.

## 2. Sztuczne sieci neuronowe


Ogólna koncepcja odwzorowania deformacji powierzchni na terenach górniczych opiera się na założeniu, że wszystkie wyniki ze specjalnie podejmowanych eksperymentów, jak również całość spostrzeżeń i obserwacji czy ekspertyz pozostają w jednoznacznym powiązaniu przyczynowo-skutkowym. Znane są sposoby określenia i oceny deformacji powierzchni z wykorzystaniem niwelacji precyzyjnej. Odwzorowanie takie byłoby dokładniejsze i wiarygodniejsze, gdyby mogło być dokonane na podstawie nie jednego, ale kilku parametrów. Aby na podstawie znajomości wyników eksperymentalnych móc przewidywać i ocenić deformację powierzchni na terenach górniczych, konieczne jest – po pierwsze – przygotowanie zbioru danych (atrybutów) objaśniających, a po drugie – opracowanie algorytmu pozwalającego na predykcję wartości objaśnianych (zmiennych zależnych), ewentualnie algorytmu wykrywania reguł opisujących powiązania między danymi. Stosowany tu termin predykcja dotyczy prognozowania, przewidywania przyszłych realizacji procesu, który z powodu braku pełnej informacji traktować trzeba jak proces stochastyczny. Jednym z istotniejszych elementów komplikujących stosowanie nowoczesnych metod obliczeniowych są trudności z dostępem do dostatecznie wiarygodnych danych. Proste zbiory danych są dostępne stosunkowo łatwo, np. wyniki niwelacji precyzyjnej przemieszczeń pionowych. Jednak tak powstałe zbiory nie uwzględniają ogromnej dynamiki zmian zachodzących w technologiach inżynierii lądowej powodującej, że uzyskane formuły szybko ulegają przedawnieniu. Zmiany, które należy uwzględnić, to m.in.:

- wprowadzanie nowoczesnych metod badawczych,
- nowe koncepcje technologiczne wydobywania węgla,
- nowe normy techniczne.

Na ogół nie jest realne świadome uwzględnienie wszystkich czynników. Możliwe to jest jednak w sposób niejawnny (częściowo w sposób nieświadomy) i dlatego jako narzędzie obliczeniowe przy realizacji oceny deformacji powierzchni na terenach górniczych zastosowano metodę typu SI – metodę sztucznych sieci neuronowych.

Pod pojęciem sieci neuronowych należy rozumieć pewną klasę matematycznych algorytmów imitujących działanie biologicznych sieci neuronowych istot żywych w celu uzyskania określonych rozwiązań problemów technicznych. Oprócz pewnej klasy algorytmów matematycznych istnieją realizacje fizyczne sztucznych sieci neuronowych, jak np. pierwsza sieć Rosenblatta czy też obecne realizacje w technologii VLSI. Większość realizacji

sieci neuronowych stosowanych w badaniach to numeryczne symulatory na klasycznych komputerach [3]. Sieci neuronowe można potraktować jako grafy skierowane, o odpowiedniej liczbie węzłów i krawędzi, które pełnią określoną rolę [3]. Najbardziej znanym przykładem sieci pracującej pod nadzorem jest sieć jednokierunkowa.



Rys. 1. Schemat sieci neuronowej  
Fig. 1. Diagram of neural network

Na rysunku 1 przedstawiono sieć jednokierunkową złożoną z trzech warstw neuronów: warstwy wejściowej (wektor wejściowy), warstwy ukrytej i warstwy wyjściowej. Warstwa wejściowa stanowi źródło informacji dla całej sieci. Przepływ informacji między neuronami w poszczególnych warstwach następuje zgodnie z kierunkami połączeń sygnałów zwanych *połączeniami synaptycznymi* z poszczególnymi neuronami. Ostatnia warstwa, tzn. warstwa neuronów wyjściowych jest związana określoną relacją – związek przyczynowo-skutkowy między wejściem i wyjściem sieci (wektor wyjściowy). Proces realizacji określonej relacji jest *procesem uczenia sieci*, który polega na adaptacji parametrów sieci zwanych *wagami* wg określonego algorytmu. Wagi są przyporządkowane krawędziom grafu i reprezentują całą wiedzę (związek przyczynowo-skutkowy) nabytą przez sieć w procesie uczenia.

Sieci neuronowe są z powodzeniem stosowane w rozwiązywaniu zadań optymalizacji, które polegają na minimalizacji funkcji, zdefiniowanej arbitralnie dla konkretnego zadania – osiągnięcia stanu równowagi sieci (stanu stabilnego) w wyniku minimalizacji zdefiniowanej wielkości charakterystycznej zwanej *funkcją błędu*, przy założeniu jednej próbki uczącej (jeden wektor wejściowy) [3].

Oprócz pojęcia *funkcji błędu* związanego z procesem uczenia lub testowania istnieją pojęcia *funkcji celu* związane z metodami optymalizacji oraz *funkcji energetycznej* przypisane dla sieci, które wymagają czasu na ustalenie odpowiedzi. Zachowanie takich sieci w czasie jest nazywane *dynamiką*. Funkcja energetyczna sieci neuronowej w czasie ewolucji czasowej maleje bądź przyjmuje wartość stałą [3].

Sztuczne sieci neuronowe, nazywane w skrócie *sieciami neuronowymi*, są to systemy w postaci konfiguracji neuronów, które w działaniu jako równoległe, rozproszone systemy obliczeniowe umożliwiają realizację dowolnego odwzorowania z przestrzeni wejściowej do przestrzeni wyjściowej [3].

Rodzaj sieci zależy od sposobu łączenia neuronów i ich wzajemnego oddziaływania. W związku z tym sieci neuronowe ulegają podziałowi na *sieci jednokierunkowe* oraz *sieci ze sprzężeniem zwrotnym*. W sieciach jednokierunkowych, które charakteryzuje statyczna zależność funkcyjna, sygnał przepływa tylko w jednym kierunku (od przestrzeni wejściowej do przestrzeni wyjściowej), natomiast w sieciach z wbudowanym sprzężeniem

zwrotnym sygnały wyjściowe neuronów przepływają do ich wejść, czyli zależą od stanu początkowego sieci i całego cyklu pobudzeń [3].

W początkowym okresie przetwarzania informacji sieci neuronowe jednokierunkowe tworzyła konstelacja neuronów ułożona w jednej warstwie. Połączenie współrzędnych wektora wejściowego z warstwą neuronów jest pełne, lecz liczba neuronów wyjściowych zależy od wymiaru wektora zadanego [3].

Proces uczenia sieci polega na optymalnym doborze wektora wag w celu wzajemnego dopasowania wektora wyjściowego do wektora zadanego, czyli na minimalizacji zdefiniowanej funkcji błędu.

Sieci neuronowe mogą służyć zarówno do rozwiązywania zagadnień aproksymacyjnych, jak i klasyfikacji. Sposoby realizacji tych funkcji są rozmaite i stanowią przede wszystkim przedmiot obszernych opracowań z zakresu sztucznych sieci neuronowych. W teorii uczenia sieci rozróżniane są dwa tryby:

- uczenie pod nadzorem,
- uczenie bez nadzoru (samodzielne), gdy danym wejściowym nie towarzyszą informacje wyjściowe.

Przy obu trybach uczenia konieczne jest odpowiednie przygotowanie – sformalizowanie danych, na których układ ma się uczyć. Dane te, zwane często zbiorem treningowym, zawierają zestawienie przykładowych kombinacji atrybutów deklaryowanych jako rozwiązania poprawne. W fazie eksploatacji wytrenowanej już sieci system dopasowuje odpowiedzi do przedłożonych mu danych testowych. Rozwiązania te są podawane wyłącznie przy uczeniu z nauczycielem, przy uczeniu bez nauczyciela sieć nie dostaje wzorcowych wartości wyjściowych.

Przy uczeniu pod nadzorem rozróżnia się więc dwie fazy pracy układu: najpierw odbywa się jego uczenie, a następnie odtwarzanie zdobytej wiedzy. Jakość działania sieci powinna być sprawdzona na zestawie danych innym niż ten użyty podczas uczenia, tzn. zbiór testowy powinien być rozłączny ze zbiorem treningowym.

Uczenie się bez nadzoru przebiega inaczej. Oparte jest ono na zjawisku samoistnej organizacji układu uczącego się i przebiega przyrostowo. Układ taki wyciąga cząstkową wiedzę z każdej przetwarzanej informacji. „Wiedza”, którą system wyciąga, jest istotnie uzależniona od sposobu działania sieci.

Narzędzia sztucznej inteligencji mają za zadanie umożliwić praktyczną, w miarę możliwości automatyczną eksploatację wiedzy ukrytej w gromadzonych bazach danych, tzn. obserwacjach, w zbiorach wyników specjalnie podejmowanych eksperymentów.

### 3. Odzworowanie deformacji powierzchni z wykorzystaniem sieci neuronowych

Analizowana baza danych ma postać zbioru wyników z badań przeprowadzonych na terenie kopalni „PIAST” w Bieruniu Nowym, z których utworzono zbiór danych przeznaczonych do uczenia i testowania sztucznych sieci neuronowych. Podstawowe dane o badanych przemieszczeniach podano w tab. 1 i 2. Zbiór stanowi 6 parametrów określonych dla poszczególnych punktów pomiarów ciągu pomiarowego. Parametry te to, odpowiednio: przemieszczenie pionowe, przemieszczenie poziome, głębokość pokładu, miąższość pokładu, odległość od filara ochronnego, odległość od frontu ściany wykopu.

Tabela 1

**Przykładowy arkusz wyników obserwacji punktów na terenie OG „Bieruń” I w 2004 r. (przemieszczenia pionowe)**

Numer ciągu	Numer punktu	Przemieszczenia pionowe					
		pomiar 1 (04.06.2004)	pomiar 2 (25.06.2004)	pomiar 3 (19.07.2004)	pomiar 4 (16.08.2004)	pomiar 5 (22.09.2004)	pomiar 6 (15.10.2004)
4	1	241,679	241,677	241,678	241,669	241,666	241,662
4	2	241,472	241,471	241,471	241,462	241,456	241,453

Tabela 2

**Parametry określone dla poszczególnych punktów ciągu pomiarowego numer 4**

Numer ciągu	Numer punktu	Głębokość pokładu 209 [m]	Miąższość pokładu 209 [m]	Odległość od filara ochronnego [m]	Odległość od ściany [m]		
					II kwartał 2004	III kwartał 2004	IV kwartał 2004
4	1	500	5,5	1583,74	649,50	515,92	398,79
4	2	500	5,5	1554,14	621,08	486,95	369,25

Do rozwiązania postawionego zadania wykorzystano sztuczną sieć neuronową jednokierunkową. W bibliotece procedur MatLaba dostępnych w Neural Network Toolbox udostępniony do poszukiwania minimum funkcji błędu średniokwadratowego jest algorytm Levenberga–Marquardta i ten algorytm wykorzystano do uczenia sieci.

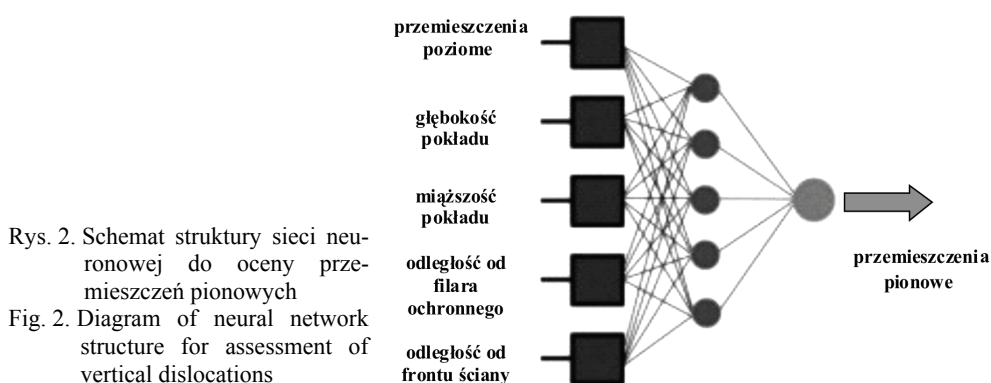
Przyjęty schemat struktury sieci – architekturę sieci – przedstawiono na rys. 2. Stanowi ją pięć wejść, jedna warstwa ukryta z pięcioma neuronami, jedno wyjście. Mieliśmy 45 wzorców, co daje 36 wzorców uczących i 9 testujących. Przy sieci o architekturze 5-5-1 mamy dokładnie 36 parametrów.

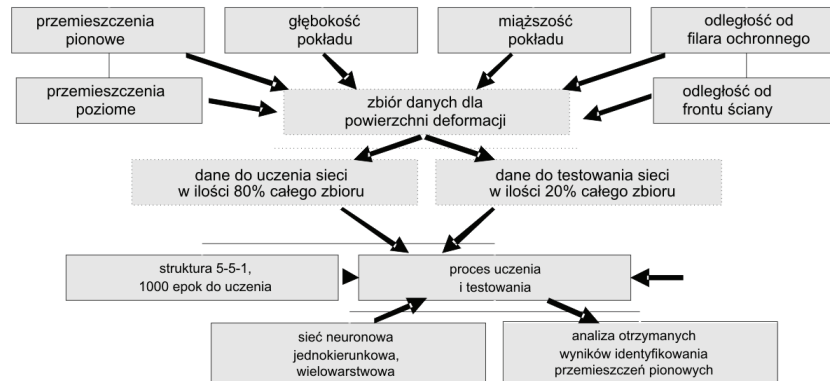
Opracowaną metodykę neuronowej identyfikacji przemieszczeń pionowych (deformacji powierzchni) przedstawia schemat pokazany na rys. 3.

Przyjęto do uczenia sieci:

- 80% danych całego zbioru,
- 20% do testowania.

Do analiz przyjęto jedną warstwę ukrytą z pięcioma neuronami.

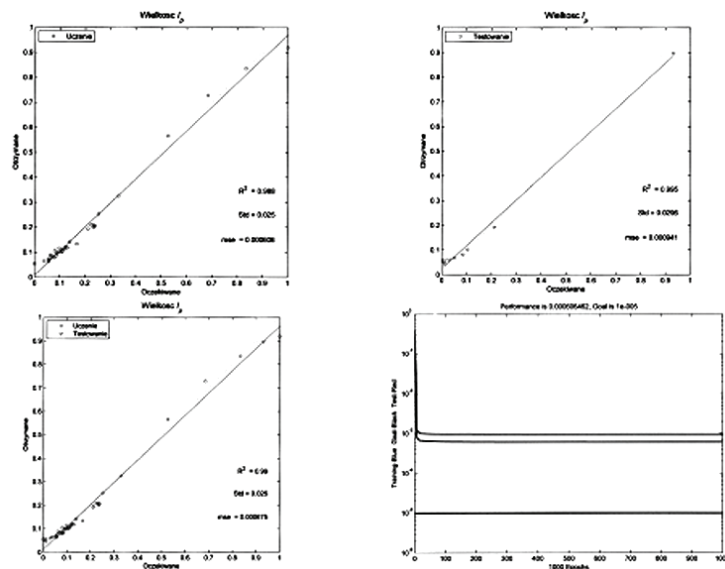




Rys. 3. Schemat metodyki identyfikacji przeszczenia pionowych  
Fig. 3. Diagram of identification methodology of vertical dislocations

#### 4. Rezultaty predykcji neuronowej

Na rysunku 4 zaprezentowano zależność między wartościami oczekiwanymi a otrzymanymi oraz wykresy MSE uczenia i testowania tej sieci neuronowej w funkcji liczby epok. Uzyskane wyniki potwierdzają, że przyjęta sieć neuronowa poprawnie odwzorowuje dane uczące i poprawnie identyfikuje dane testujące. Potwierdza to „ułożenie” punktów



Rys. 4. Zależność między wartościami oczekiwanymi a otrzymanymi oraz wykresy błędów MSE uczenia i testowania sieci w funkcji liczby epok

Fig. 4. Relation between learning and testing set and diagrams of MSE errors of learning and testing network in function of epochs number

blisko prostej oraz uzyskane wartości współczynnika korelacji  $R$  (bliskie jedności) oraz błąd MSE, który bardzo szybko maleje wraz z rosnącą liczbą epok (rys. 3). Z ostatniego wykresu widać wyraźnie, że do testowania sieci w funkcji liczby epok wystarczy 50 epok, przyjęte więc 1000 epok jest zupełnie zbędne.

## 5. Wnioski

Przedstawione rezultaty potwierdzają, że za pomocą sztucznych sieci neuronowych, w tym szczególnie sieci z algorytmem Levenberga–Marquardta, możliwa jest predykcja przemieszczeń pionowych na podstawie przyjętych parametrów, takich jak: przemieszczenia poziome, głębokość pokładu, miąższość pokładu, odległość od filara ochronnego, odległość od ściany wykopu. Potwierdzają to przede wszystkim obliczone niskie wartości błędów MSE uczenia i testowania neuronowej jednokierunkowej sieci w liczbie funkcji epok i bliskie jedności wartości współczynnika korelacji  $R$  dla testowania.

## Literatura

- [1] Brandt A., Kasperkiewicz J., *Metody diagnozowania betonów i betonów wysokowartościowych na podstawie badań strukturalnych*, IPPT PAN, Warszawa 2003.
- [2] Cichosz P., *Systemy uczące się*, WNT, Warszawa 2000.
- [3] Gil J., *Przykłady zastosowań sieci neuronowych w geodezji*, OWUZ, Zielona Góra 2006.
- [4] Osowski S., *Sieci neuronowe do przetwarzania informacji*, OWPW, Warszawa 2000.